

面向千万级上下文的逐步稀疏检索与并行验证系统

一句话结论：在 10M 真实文本中，每题最多 retrieval 4,864 tokens (约占全文 0.049%)，二跳问答正确率达到 36.4%，显著超过 10K/20K/40K full attention 的 21.2%/16.6%/9.4%，单题延迟可从 1 卡 8.99s 降至 6 卡 2.60s。

技术报告

日期：2026-07-13

实验平台：8 x NVIDIA RTX 3090 (按空闲情况使用 1/2/4/6 卡)

主要模型：Qwen3-0.6B、Qwen3-8B

主要数据：Official MuSiQue 2-hop + 10M real-text distractor corpus

摘要

本项目研究一个面向超长上下文推理的问题：当历史文本或 KV cache 的规模达到千万乃至十亿 tokens 时，模型是否可以在每一步生成前只检索少量当前所需证据，并通过多次状态更新完成连续推理，而不必一次性读取全部上下文。

我们构建了一个包含 **9,999,872 tokens**、**39,062 个 256-token blocks** 的真实文本索引，并将 2,000 条 Official MuSiQue 二跳问题的支持段落对齐到该索引中。系统不使用合成高斯向量；检索中的低秩特征来自 Qwen 的真实前向 Q/K。最终系统采用词法粗检索、四通道 SVD32 模型内生重排、8B bridge 生成、无泄漏状态写回、第二跳 Top16 召回、逐 block 候选抽取和冻结 Yes/No verifier。

在冻结的 500 条外部测试问题上，当前最强系统达到 **36.4% (182/500) 严格 Answer Hit**。作为对照，即使保证两条 gold evidence 都在上下文中，Qwen3-8B 直接 full attention 读取 10K、20K 和 40K tokens 的结果也只有 **21.2%、16.6% 和 9.4%**。同题配对下，10M 检索系统分别领先 **15.2、19.8 和 27.0 个百分点**，差异均具有统计显著性。

同请求多卡并行实验表明，当前 16 分支 verifier 系统的平均在线延迟可从 1 卡的 **8.99s** 降至 2 卡的 **5.10s**、4 卡的 **3.18s** 和 6 卡的 **2.60s**；对应加速为 **1.76x、2.83x 和 3.46x**。2 卡具有最高并行效率，4 卡是更合理的低延迟折中，6 卡最低延迟但 GPU-seconds 明显增加。

这些结果支持以下结论：逐步稀疏检索不仅绕过了上下文窗口限制，也能缓解长上下文中的证据稀释、竞争实体和关系绑定错误。但当前系统仍未达到近似无损：gold state + 唯一 gold paragraph 的局部 reader oracle 为 70.8%，当前 36.4% 仅保留约 51.4% 的该上限。后续工作的重点应是 matched stepwise full-attention 对照、candidate extractor/verifier 蒸馏、风险门控和更多任务及模型的泛化验证。

1. 问题定义

1.1 长期目标

导师提出的目标是从约 1B 数据中检索 1M 有效数据。本项目先验证一个缩小但仍具有系统意义的版本：

```
10M real-text tokens
-> 39,062 blocks
-> 每一步检索少量 blocks
-> 模型持续生成并更新查询状态
-> 完成二跳问答
```

核心研究假设是：

对自回归模型而言，每一个局部生成步骤可能只依赖 1--3 个证据 blocks。模型不必一次性获得全部前置条件；它可以生成一个中间状态，再以该状态检索下一批证据。

1.2 研究问题

本报告集中回答四个问题：

- 1. **RQ1**：能否从 10M 真实文本中检索二跳推理所需的少量证据？
- 2. **RQ2**：真实 Q/K 的 SVD32 低秩空间能否作为有效语义检索信号？
- 3. **RQ3**：稀疏逐步系统能否优于远短于 10M 的 full-attention 上下文？
- 4. **RQ4**：16 分支 candidate/verifier 系统能否通过多卡并行降低在线单题延迟？

1.3 本项目不研究的内容

- 不把合成高斯向量上的召回当作真实检索证据。
- 不假设 attention/QK 分数天然等价于文本语义相关性。
- 不把 fu11128 自定义分数称为全模型 attention oracle。
- 不在评测时使用 gold answer 或 gold block 选择候选。
- 不宣称已经执行 10M full attention；Qwen3-8B 的原生窗口无法容纳 10M tokens。

2. 数据与实验协议

2.1 10M 对齐语料

最终主实验使用 `musique_official_10m_aligned_2000_v3`：

项目	数值
总 tokens	9,999,872
block size	256 tokens
blocks	39,062
Official MuSiQue questions	2,000
train/dev/test	1,000 / 500 / 500
对齐支持 blocks	2,816
平均支持段落长度	113.14 tokens
p95 支持段落长度	215 tokens

每条支持段落完整位于一个 block 内；其它 tokens 来自真实 MuSiQue distractor paragraphs。最终语料不包含合成文本、合成向量或 padding tokens。

2.2 二跳问题示例

典型问题由两条事实构成：

```
Lou Breslow's wife was Marion Byron.
Marion Byron was born in Dayton, Ohio.
Question: Where was Lou Breslow's wife born?
Answer: Dayton, Ohio.
```

系统必须先从第一条证据生成 bridge entity `Marion Byron`，再以该实体和第二跳关系检索出生地证据。

2.3 数据泄漏约束

严格链要求：

1. 第一跳检索不知道 gold block 和答案。
2. bridge 必须由模型生成，不能用 gold entity 修正。
3. 第二跳的 `lookup_key`、`step_question`、`retrieval_state` 和 compact/full state 都必须由生成 bridge 重写。
4. train-only passage head 和 verifier 只使用 train split 训练或校准。
5. test gold 只用于最终统计，不参与候选生成、排序或选择。

早期实验曾发现第二跳状态中残留 gold bridge 的问题；相关结果已全部作废并重新运行。当前报告只使用无泄漏链结果。

2.4 评测指标

检索指标

- `Recall@K`：gold block 是否进入前 K 个候选。
- 条件召回：例如给定 bridge 正确时的第二跳 `Recall@16`。

生成指标


- `Answer Hit`：标准化后 gold answer 是否完整出现在输出中。
- `Exact Match`：标准化输出是否等于 gold answer。
- Token F1：与 LongBench QA 类似的 token overlap F1。

系统指标

- 单请求 mean / median / p95 latency。
 - 相对 1 卡 speedup： `T1 / TN`。
 - 并行效率： `speedup / N`。
 - GPU-seconds/题： `GPU 数 x 单题墙钟`。
-

3. 系统设计

3.1 总体流程



系统不是单纯的 embedding RAG：词法检索承担全局高召回入口，真实 Q/K 的低秩信号只作为候选集上的模型内生 residual ranker；随后由生成模型完成状态转移和关系抽取。

当前职责划分为：Qwen3-0.6B 提供真实 Q/K profile 和冻结的 SVD32 passage-ranking 信号，Qwen3-8B 负责 bridge 生成、第二跳候选抽取与最终 support verification。因此当前主结果不是单一模型的纯检索成绩，而是一个检索器与 reader 分工的完整系统结果。

3.2 Block 索引

10M tokens 被切分为 39,062 个 256-token blocks。常驻词法 postings 可以在约 0.69ms 内返回大候选集。第二跳常驻 BM25 matrix 对 500 条 query 的查询时间为 0.585s，约 1.17ms/题；一次性建库约 23.9s，不计入在线延迟。

3.3 真实 Q/K 与 SVD32

早期实验表明，固定 Q/K head 的原始高分常被模板分隔符、标点和通用短语主导。因此当前方法使用真实 causal prefill 中的 pre-RoPE K，并在 calibration K 上拟合 centered SVD：

```
Kc = K - mean(K)
Kc ~= U_r Sigma_r V_r^T
k_r = Kc V_r
q_r = q V_r
score_r(q, k) = q_r k_r^T
```

当前在线维度为 `r=32`。四个代表性 layer/query-head 通道为：

L3/H10, L21/H8, L6/H7, L16/H14

四通道 K 的 rank-32 子空间平均保留约 97.5% 能量，存储和传输维度从 128 降至 32。系统从问题内容中选择多个 Q token，在候选 block 内执行归一化 late interaction，再由 train-only passage head 与词法/rank 特征融合。

关键定位是：

SVD32 不是独立替代 BM25 的通用 embedding，而是 lexical coarse retrieval 后的模型内生语义残差分数。

3.4 第一步：Bridge 生成

第一跳从 10M 中取得 Top3 blocks，将三个 blocks 拼接后由 Qwen3-8B 使用 atomic direct-answer prompt 生成 bridge。相比 0.6B，8B 显著提高关系值读取能力：

Reader	Overall bridge	给定 Top3 召回成功
Qwen3-0.6B	44.2%	55.76%
Qwen3-8B	67.2%	82.84%

显式自由文本 CoT 并未改善 0.6B，反而增加格式和关系选择错误。因此当前 prompt 要求直接输出最短实体，而不是生成推理链。

3.5 第二步：状态写回与重新检索

生成 bridge 被写回所有活动查询字段，然后重新查询 39,062 blocks。8B bridge 链的第二跳召回为：

指标	Recall
Top1	11.0%
Top3	47.0%
Top16	69.8%
给定 bridge 正确时 Top3	61.01%
给定 bridge 正确时 Top16	89.29%
bridge 错误时 Top16	29.88%

这说明 bridge 正确后，第二跳证据通常能进入 Top16，但很难稳定压缩到 Top3。

3.6 Top16 候选抽取与 Support Verifier

直接把 Top16 共 4,096 tokens 拼接给模型只达到 33.0%，原因是多个相似 blocks 产生竞争实体和值。当前最强方案把 Top16 当作候选池：

1. 对每个 block 独立使用 atomic prompt 抽取最短答案候选。
2. 对 `question + block + candidate` 计算冻结 Qwen3-8B 的 Yes/No support margin。
3. 选择 support margin 最大的候选。

这种解耦将“答案抽取”和“证据支持判断”分开，避免生成式 `SUPPORTED/NOT_SUPPORTED` 的高假阴性。

4. 方法演进与关键负结果

4.1 合成向量实验的边界

早期高斯向量 benchmark 只验证并行扫描、SVD 近似和 top-K kernel 的系统能力。因为正样本与 query 的相似关系由构造过程预先定义，它不能证明真实模型 Q/K 可以找到自然语言证据。最终主实验已完全切换到真实文本、真实模型前向和无泄漏 query。

4.2 为什么固定 `fu11128` 找不到证据

在早期 clean64 真实 LongBench retrieval benchmark 中，旧 `fu11128` 只是四个抽样 profile 的 128 维自定义 reference，不是完整模型 attention。失败原因包括：

- 只取统一 `Answer:` 末尾 token 的单个 Q，query 之间高度相似。
- block-max 容易被冒号、引号和通用短语劫持。
- 不同 heads 的语义专长不同，raw logit 不可直接跨 head 比较。
- post-RoPE Q/K 跨独立 records 比较会引入不一致的位置相位。

清洗数据、改用 pre-RoPE multi-Q 和词法入口后，answer-block Recall@39 从 0 提升到 82.81%，证明原失败主要来自错误的检索定义，而不是 SVD 本身完全无效。

4.3 BM25 为什么经常强于纯 Q/K

在 39K blocks 的全局空间中，实体词和专有名词是极强的过滤信号。纯 attention/QK 分数可能关注回答格式、关系词或局部生成模式，却未必唯一定位支持段落。因此：

- BM25/postings 适合作为高召回 coarse retrieval。
- SVD32 适合在小候选集中增加 relation-sensitive 信号。
- 纯 Q/K 全库扫描不应作为唯一检索器。

4.4 全层全 Head 共识为何没有直接解决问题

全 448 query heads 的 Top16 候选并集可将 answer recall 提高到 71.88%，说明专业 heads 确实互补。但多数共识 Top39 只有 31.25%，因为只被少数专业 heads 关注的 gold block 会被多数票删除。正确方向是 head routing 或 head-group quota，而不是简单多数投票。

4.5 为什么 Top16 拼接收益有限

Gold block 排名	问题数	Top3 拼接	Top16 拼接
Rank 1--3	235	55.32%	50.64%
Rank 4--16	114	18.42%	35.09%
>16 / 未召回	151	4.64%	3.97%

Top16 能救回 rank4--16 的证据，但额外 13 个 distractors 会破坏原本 Top3 已足够的问题。扩大 raw context 不是稳定解法，必须进行逐块候选化或风险门控。

5. 主要质量结果

5.1 完整 500 条测试集

方法	上下文/策略	最终 Answer Hit
Top3 concat	3 blocks, 768 tokens	31.6% (158/500)
Top16 concat	16 blocks, 4,096 tokens	33.0% (165/500)
Answer-likelihood selector	16 candidates	29.4%
Yes/No support selector	16 candidates	36.4% (182/500)
16 candidates 任一正确 oracle	16 candidates	48.8% (244/500)
Gold block + gold state	1 block	68.8% (344/500)
Gold paragraph + gold state	1 paragraph	70.8% (354/500)

Yes/No selector相对 Top3 concat 为 67 胜 43 负，p=0.0279；相对 Top16 concat 为 +3.4pp，但当前样本上尚未达到显著性（56 胜 39 负，p=0.1002）。

表中最后两条 gold-evidence 结果是给定正确二跳状态后的局部 reader diagnostic，不是原始二跳问题的完整端到端 oracle；它们用于估计 reader 上限和剩余差距。

5.2 各阶段损失

阶段	成功率	解释
第一跳 gold block 进入 Top3	74.6% (373/500)	第一跳检索损失
8B bridge 正确	67.2% (336/500)	检索 + 关系读取损失
第二跳 gold block 进入 Top16	69.8% (349/500)	错误状态与候选排序损失
16 个候选至少一个答案正确	48.8% (244/500)	reader 抽取损失
Verifier 最终选对	36.4% (182/500)	多候选选择损失

在 244 个至少有一个正确候选的问题中，verifier 选对 182 个，条件选择率为 74.6%。正确候选相对错误候选的 branch-pair 排序准确率为 74.32%，但每题需要与最多 15 个 hard negatives 比较；一个异常高分负例即可覆盖正确候选。

5.3 对当前效果的评价

36.4% 具有两面性：

- **作为可行性结果：** 有意义。系统从 39,062 blocks 中完成二跳状态更新，并显著优于 10K--40K one-shot full attention。
- **作为近似无损结果：** 不足。相对 70.8% 局部 oracle，当前仅保留约 51.4%。

因此准确表述应是：

当前结果证明了超长上下文中的逐步稀疏检索具有真实系统收益，但误差传播和 reader/verifier 能力仍使最终性能距离近似无损存在明显差距。

6. Full-Attention 长度基线

6.1 构造协议

对同一批 500 条测试题分别构造 10K、20K、40K contexts：

- 两条 gold support blocks 均保证完整存在。
- distractors 来自同一 10M 真实 MuSiQue 语料。
- 同一问题满足 10K distractors $\subset$ 20K $\subset$ 40K。
- 两条证据均衡分布在 early/middle/late 六种有序位置组合。
- Qwen3-8B 直接回答原始二跳问题，不做检索或显式分步。

6.2 结果

Context	Answer Hit	95% CI	Exact Match	Token F1	Mean latency
10K	21.2%	[17.84%, 25.00%]	15.8%	30.84	3.11s, 1 GPU
20K	16.6%	[13.60%, 20.11%]	11.6%	25.39	7.07s, 1 GPU
40K	9.4%	[7.14%, 12.28%]	5.4%	16.17	17.99s, 2 GPU

长度增加导致质量单调下降，同时计算时间快速增加。配对结果为：

比较	长上下文独有正确	短上下文独有正确	McNemar p
10K -> 20K	19	42	0.00444
10K -> 40K	15	74	1.53e-10
20K -> 40K	18	54	2.57e-5

6.3 与 10M 检索系统逐题配对

对照	Full attention	10M 检索	检索提升	检索胜/负	p
10K	21.2%	36.4%	+15.2pp	128 / 52	1.40e-8
20K	16.6%	36.4%	+19.8pp	137 / 38	2.46e-14
40K	9.4%	36.4%	+27.0pp	159 / 24	1.27e-25

这一结果说明稀疏选择的价值不仅是缩短输入，还包括减少竞争事实和关系混淆。

但这不是纯检索器的完全公平对照：10M 系统还包含显式二跳分解、bridge 生成、candidate extraction 和 verifier，而 full-attention baseline 是 one-shot 生成。要把增益严格归因于 sparse retrieval，还需运行 matched stepwise full-attention baseline。

7. 在线时间与多卡并行

7.1 检索本身的时间

当前在线检索约为：

阶段	时间
10M postings / lexical entry	约 0.69ms
SVD32 residual rerank 与 Q capture	约 41.4ms/step
第二跳常驻 BM25	约 1ms/题

阶段	时间
合计采用值	约 42.5ms/题

因此主要延迟不在 10M 检索，而在 8B 的 16 路候选生成和 verifier。

7.2 同请求 1/2/4/6 卡加速

固定 30 条测量题和 2 条预热题，所有 GPU 数重新执行 bridge、16 路候选生成和 16 路 Yes/No verifier。模型加载不计时间，检索的 42.5ms 被加回在线总时间。

GPU	Mean	Median	p95	Speedup	Efficiency	GPU-s/题
1	8.993s	8.040s	14.593s	1.00x	100.0%	8.99
2	5.101s	4.730s	7.837s	1.76x	88.1%	10.20
4	3.177s	2.975s	5.330s	2.83x	70.8%	12.71
6	2.598s	2.462s	4.081s	3.46x	57.7%	15.59

四种卡数下 bridge replay 匹配率均为 100%，输出质量没有因并行改变。

7.3 分阶段加速

GPU	Bridge	16 路答案生成	16 路 Verifier
1	0.487s	7.032s	1.432s
2	0.483s	3.872s	0.703s
4	0.485s	2.268s	0.382s
6	0.489s	1.777s	0.289s

Verifier 在 6 卡达到 4.95x，答案分支达到 3.96x。Bridge 始终约 0.49s，是不可并行的串行部分。16 个 branches 不能被 6 整除，且各分支生成长度不同，因此 6 卡效率降至 57.7%。

7.4 工程配置建议

- **1 卡**：最低资源消耗，约 8.99 GPU-seconds/题。
 - **2 卡**：最佳延迟/资源效率，5.10s、88.1% 并行效率。
 - **4 卡**：更合理的交互延迟点，约 3.18s/题。
 - **6 卡**：最低延迟演示，约 2.60s/题，但相对 4 卡只再改善 18.2%。
-

8. 主要误差分析

8.1 第一跳未召回

第一跳 Top3 recall 为 74.6%。当正确 block 未进入 Top3 时，8B bridge 仍有 21.26% 偶然正确，来源可能是参数知识、替代证据或实体猜测，但不能视为检索成功。

8.2 Bridge 错误导致查询漂移

错误 bridge 会改变第二跳实体锚点，使检索进入错误事实簇。正确 bridge 时第二跳 Top16 recall 为 89.29%，错误 bridge 时只有 29.88%。因此第一跳状态质量是误差传播的关键控制点。

8.3 正确证据进入 Top16 仍无法抽取答案

16 candidates 任一正确率只有 48.8%，低于第二跳 block Recall@16 的 69.8%。这说明证据被召回后，8B 仍可能：

- 选择同 block 中的错误关系值；
- 输出 bridge 或 subject，而不是目标 relation value；
- 选择邻近人物、年份、地点或数值；
- 产生 benchmark 不接受的替代事实或过长答案。

8.4 Verifier 的多负例最大值问题

Verifier 的 branch-pair 排序约 74%，单看似乎较强；但每题要从 16 个 candidates 取最大值。只要 15 个负例中有一个得到异常高 support score，正确候选就会被覆盖。62 次选择损失中，57 次错误 winner 来自非-gold block，说明 hard-negative calibration 是主要问题。

8.5 Full attention 的证据稀释

在 40K context 中，即使两条 gold evidence 都存在，模型仍可能被电影主演、同名人物、相似关系和邻近数值吸引。六种 gold 位置组合的 Answer Hit 都很低，说明退化并非单一的 `lost in the middle`，而是位置偏差、证据稀释和关系绑定共同作用。

9. 对研究问题的回答

RQ1：能否从 10M 中找到有用证据？

可以，但尚未近似无损。第一跳 Top3 recall 为 74.6%，第二跳 Top16 recall 为 69.8%；给定 bridge 正确时第二跳 Top16 达到 89.29%。这证明 39,062 blocks 的全局索引具备实际可用性。

RQ2：SVD32 是否有用？

有用，但适合做 residual ranker，不适合单独替代 BM25。Rank32 保留约 97.5% K 能量；train-only passage head 在 1,000 个外部 steps 上将 Top3 recall 从 65.9% 提高到 68.7%，`p=0.0072`。纯 Q/K 全库排序仍容易被通用高分模式干扰。

RQ3: 10M 检索是否优于 full attention?

作为完整系统，显著优于 10K--40K one-shot full attention。当前 36.4% 相对 10K/20K/40K 分别提高 15.2/19.8/27.0pp。但仍需 matched stepwise baseline 才能把增益完全归因于检索，而不是显式分解和 verifier。

RQ4: 多卡并行是否有效?

有效。6 卡把同请求平均延迟从 8.99s 降到 2.60s；2 卡效率最高，4 卡是较合理的低延迟折中。继续增加 GPU 会受串行 bridge、分支不均衡和同步开销限制。

10. 结论边界与有效性威胁

10.1 可以支持的结论

1. 真实 Q/K 的低秩信号可以作为词法检索后的有效模型内生重排特征。
2. 每一步只加载少量 evidence blocks 的迭代系统可以在 10M 索引上完成真实二跳推理。
3. 长上下文中的更多原文不必然提高推理质量，甚至会显著降低答案准确率。
4. 候选分支天然适合多 GPU 同请求并行。

10.2 当前不能支持的结论

1. 不能声称当前已经实现 10M -> 少量 blocks 的近似无损推理。
2. 不能声称 SVD32 单独优于 BM25；当前最好方法依赖 lexical + SVD32 融合。
3. 不能声称 10M 检索相对 matched stepwise full attention 已经获胜；该对照尚未运行。
4. 不能将速度子集的 50% accuracy 当作完整测试集结果；完整 500 条仍为 36.4%。
5. 不能把 40K 的趋势数值外推成 10M full-attention 实测结果。
6. 不能宣称跨任务或跨模型泛化；当前最完整证据集中在 MuSiQue 2-hop 和 Qwen3 系列。

10.3 指标口径限制

本报告的主要质量指标是严格 Answer Hit。LongBench 官方不同任务分别使用 F1、ROUGE-L、Accuracy 等指标，因此本报告的 36.4% 不能直接与 LongBench 宏平均分横向比较。后续论文应同时报告 MuSiQue 官方 F1/EM 和本项目的严格 Answer Hit。

11. 下一步工作

11.1 最高优先级: Matched Stepwise Full-Attention Baseline

在相同 10K/20K/40K context 上执行与检索系统完全相同的两步流程：

1. 用 atomic prompt 生成 bridge。
2. 将 bridge 写回第二跳 query。
3. 再读取同一 full context 生成 final answer。

该实验只改变 evidence access：一个读取 full context，一个检索少量 blocks。它是区分“检索收益”和“任务分解收益”的最关键对照。

11.2 Candidate Extractor 蒸馏

当前单卡 16 路答案生成占 7.03s，是最大在线瓶颈。应使用 8B 输出构造无泄漏监督数据，将 relation-conditioned atomic extraction 蒸馏到 0.6B/1.7B 级模型，并保留 8B 作为低置信度 fallback。

11.3 Verifier 蒸馏与校准

将 8B Yes/No support margin 蒸馏成轻量 cross-encoder 或小型分类头，并重点优化：

- 16-way Top1 calibration，而不只是 pairwise accuracy；
- hard-negative mining；
- alternative-fact 与 benchmark-supported-fact 区分；
- 分数校准和 abstention。

11.4 风险门控与动态预算

推荐的运行策略是：

高置信度 -> Top3 直接回答
中等风险 -> 扩展到 Top6/Top8
高风险 -> Top16 candidate extraction + verifier

这可以避免所有问题都支付 16 分支成本，并使系统从固定预算转向 sample-adaptive budget。

11.5 检索侧改进

- 学习 head/operator routing，而不是全 head 多数投票。
- 为 bridge、人物关系、地点、日期和数值关系建立不同 specialist groups。
- 将 block rerank 升级为 relation-conditioned support scoring。
- 研究多 bridge hypothesis 的条件保留，而不是过早压成单一状态。

11.6 泛化验证

- 扩展到 HotpotQA、2WikiMQA 和其它 LongBench multi-doc QA。
- 使用 Qwen3-4B/14B 或其它模型验证 reader 与检索器的模型依赖性。
- 从 10M 扩展到 100M，再评估索引分片、通信和多机扩展。
- 在 8 GPU 全空闲时补测 8 卡同请求并行；16 branches 可均匀分为每卡 2 个。

12. 总结

本项目已经从“合成向量能否并行检索”的系统原型，推进到“真实 10M 文本、真实模型 Q/K、无泄漏二跳状态传播、完整答案生成和多卡在线延迟”的端到端研究原型。

最重要的经验不是某一个单独的检索分数，而是以下系统事实：

1. **全局入口需要词法召回。** 纯 attention/QK 分数不能稳定承担 39K blocks 的唯一检索入口。
2. **SVD32 有真实价值。** 它能以四分之一维度保留大部分 K 子空间，并作为模型内生 residual ranker 提高候选质量。
3. **推理必须逐步更新状态。** 第一跳 bridge 质量直接决定第二跳 query 是否漂移。

- 4. **更多上下文不等于更多有效信息。** 10K--40K full attention 在保证 gold evidence 存在时仍随长度显著退化。
- 5. **Top16 应被视为候选池，而不是直接拼接文本。** 独立抽取和支持验证优于无条件扩大 raw context。
- 6. **分支并行能够降低延迟。** 1 卡 8.99s 可降至 6 卡 2.60s，但 2--4 卡更具资源效率。

综合而言，核心 idea 已获得明确的可行性证据：

在海量上下文中，模型可以围绕当前生成状态检索少量证据，生成新的中间状态，再继续检索和生成；这种逐步稀疏推理可以优于一次性读取更长的上下文。

当前研究的下一阶段不应继续单纯扩大 TopK 或堆叠相似度，而应集中解决 **状态可靠性、候选支持验证、动态预算和小模型蒸馏**。只有完成 matched baseline、跨任务验证并显著缩小相对 70.8% oracle 的差距后，才适合进一步主张近似无损的超长上下文推理。

附录 A：关键结果索引

内容	文档/结果
10M 逐步链、reader、Top16、verifier	ymluo/doc/section184_10m_anchor_gated_stepkv_chain_20260712.md
10K/20K/40K full-attention baseline	ymluo/doc/section197_full_context_length_baseline_20260712.md
1/2/4/6 GPU 同请求并行	ymluo/doc/section198_verifier_system_gpu_scaling_20260712.md
Full-context 汇总	ymluo/projects/parallel_block_retrieval/outputs/musique_fullcontext_10k20k40k_test500_v3/summary.json
Full-context 与 10M 配对	ymluo/projects/parallel_block_retrieval/outputs/musique_fullcontext_10k20k40k_test500_v3/paired_vs_10m_retrieval.json
多卡 scaling 汇总	ymluo/projects/parallel_block_retrieval/outputs/musique_verifier_system_scaling_30q_v1/scaling.json

附录 B：主要复现脚本

```
ymluo/projects/parallel_block_retrieval/src/evaluate_full_context_length_baseline.py
ymluo/projects/parallel_block_retrieval/src/compare_full_context_to_retrieval.py
ymluo/projects/parallel_block_retrieval/src/benchmark_verifier_system_same_query_scaling.py
ymluo/projects/parallel_block_retrieval/src/analyze_verifier_system_scaling.py
ymluo/projects/parallel_block_retrieval/scripts/run_verifier_system_scaling_1_2_4_6.sh
```