

2026-05-19 MoE Selectivity 合成数据实验记录

指标说明: `same_higher_by_layer` 表示同一个 higher-level unit 被分发到同一个 expert 的比例;
`higher_mass_by_layer` 表示 attention 落在同一 higher-level history token 上的质量;
`expert_load` 表示不同 expert 的平均路由负载。

Exp1: 对其它 expert / gate 列向量施加 negative gradient

实验目的: 让别的 expert / gate 的其它列向量拿到反向负梯度, 观察是否能提升 expert selectivity。

step	loss	acc	same_higher_by_layer	higher_mass_by_layer	expert_load
100	1.4925	0.7676	L0:0.4316 L1:0.5558 L2:0.6765	L0:0.2997 L1:0.2578 L2:0.3173	[0.1736, 0.2397, 0.2717, 0.3149]
1100	0.2673	0.9128	L0:0.4673 L1:0.9781 L2:1.0000	L0:0.3636 L1:0.4257 L2:0.4200	[0.1393, 0.3073, 0.2292, 0.3240]
10000	0.2607	0.9139	L0:0.4568 L1:0.9826 L2:1.0000	L0:0.3808 L1:0.4341 L2:0.4273	[0.1402, 0.3076, 0.2288, 0.3232]

结论: 为其它 expert 施加反向负梯度效果非常好, 基本能够让每个 expert 专注于同一个 higher-level unit 元素。

Exp2: 小 batch / token 更新

实验目的: 每次只更新一个 token, 验证类似人脑 inhibition 的逐条数据学习机制是否能提升 gating selectivity。

step	loss	acc	same_higher_by_layer	higher_mass_by_layer	expert_load
10000	4.5524	0.0556	L0:0.7572 L1:0.5807 L2:0.7301	L0:0.2470 L1:0.2680 L2:0.2648	[0.2160, 0.3237, 0.1273, 0.3328]
100000	1.0697	0.7883	L0:0.2849 L1:0.5347 L2:0.5712	L0:0.2746 L1:0.2415 L2:0.2627	[0.2137, 0.2238, 0.2935, 0.2687]
300000	0.9383	0.8090	L0:0.3002 L1:0.6541 L2:0.6161	L0:0.2947 L1:0.2485 L2:0.2763	[0.2323, 0.2549, 0.2259, 0.2866]

结论: 逐 token 学习效果不错, 基本能够让同一个 higher-level unit 元素分发到同一个 expert 里。缺点是训练速度太慢, 预计 100w step 才能达到之前约 1000 step 的训练 loss。

Exp3: expert 初始化调整

实验目的: 验证 expert 初始化或 gate 初始化是否显著影响最终训练出的 selectivity。

Exp3.1: expert 两两 Frobenius 内积正交初始化后直接训练

step	loss	acc	same_higher_by_layer	higher_mass_by_layer	expert_load
100	1.4884	0.7679	L0:0.3209 L1:0.3625 L2:0.3840	L0:0.2994 L1:0.2572 L2:0.3140	[0.2174, 0.2864, 0.2649, 0.2311]

step	loss	acc	same_higher_by_layer	higher_mass_by_layer	expert_load
1000	0.2687	0.9126	L0:0.3033 L1:0.3477 L2:0.3419	L0:0.3483 L1:0.3862 L2:0.3762	[0.2429, 0.2413, 0.2692, 0.2463]
10000	0.2608	0.9125	L0:0.3027 L1:0.3207 L2:0.3410	L0:0.3602 L1:0.4174 L2:0.3955	[0.2430, 0.2486, 0.2365, 0.2717]

结论：Frobenius 内积正交初始化没法有效让相同 higher-level unit 选择相同 expert。

Exp3.2: 前 1000 步强制同一 higher-level unit 选择相同 expert

step	loss	acc	same_higher_by_layer	higher_mass_by_layer	expert_load
100	1.5110	0.7650	L0:0.3451 L1:0.3422 L2:0.3560	L0:0.2996 L1:0.2564 L2:0.3118	[0.3052, 0.2031, 0.2548, 0.2367]
1000	0.4252	0.8808	L0:0.4413 L1:0.4842 L2:0.5174	L0:0.3351 L1:0.2831 L2:0.2990	[0.5068, 0.0635, 0.0426, 0.3869]
10000	0.2604	0.9136	L0:0.3796 L1:0.3106 L2:0.3158	L0:0.3851 L1:0.4466 L2:0.4259	[0.2868, 0.2260, 0.1511, 0.3360]

结论：前置强制选择 expert 的初始化会在前 1000 步让 same_higher_by_layer 明显上升，但去除 force 选择后该指标明显下降，1w step 后下降到接近正常水平。

Exp3 总结：初始化参数对模型后续训练影响较小，模型会逐渐将参数向 baseline 靠近。