

从 Evidence Attention Mass 到输出 Margin: Qwen3-8B 的逐层机制分析



图 1 实验背景。上图为 34--100 token 密集扫描中的全模型证据 attention mass，下图为正确答案 `basket` 相对完整词表中最强竞争 token 的 logit margin。绿色短线表示首 token 正确，红色短线表示首 token 进入解释前缀。图中标出的 48-token 点同时出现 evidence mass 降低和 margin 穿过零点。

核心问题与结论

本文回答的问题是：

查询位置分配给正确证据的 attention mass 降低以后，中间经过了哪些模型计算，最终导致正确答案 token 的输出 margin 降低？

核心链条为：

QK 匹配 → evidence mass → Value 读取 → residual stream 写入 → 后续层传播 → 输出 logit margin.

其中，attention mass 不会直接变成答案概率。它首先决定证据 Value 与背景 Value 在 attention 输出中的混合比例；该向量经过 W_O 写入 residual stream，再经过后续 attention、MLP、RMSNorm 和 LM head，最终改变正确答案与竞争 token 的 logit 差。

本实验最重要的定量结果是：

- 47 → 48 时，全模型原子证据 mass 从 1.4225% 降至 1.1271%，下降 20.8%。
- L30--33 原子证据 mass 从 2.8269% 降至 2.3221%，下降 17.9%。
- `basket` 相对 `Let` 的 margin 从 +1.781 降至 -0.141，变化 -1.922。
- 在完整 34--100 token 扫描中，L30--33 evidence mass 与完整词表 margin 的相关系数为 $r = 0.920$ ，线性解释度为 $R^2 = 0.846$ 。

这里的证据集合 E 指四个原子位置：

$$E = \{\text{start key, hop1 result, hop2 input, hop2 result}\}.$$

需要注意：47 与 48 的样本由 `middle` 放置策略重新居中，局部 filler 和证据绝对位置同时发生变化，因此该转折不是“在完全相同的序列末尾只追加一个 token”的严格长度干预。本文分析的是：**在已经观察到 mass 降低的条件下，这个变化如何沿模型计算路径传递到输出 margin。**

1. 从 QK 匹配得到 evidence attention mass

对第 ℓ 层、第 h 个 attention head，最终查询位置对历史 token i 的 pre-softmax 分数为：

$$s_{\ell hi} = \frac{\tilde{\mathbf{q}}_{\ell h}^\top \tilde{\mathbf{k}}_{\ell hi}}{\sqrt{d_h}}.$$

其中 $\tilde{\mathbf{q}}$ 和 $\tilde{\mathbf{k}}$ 是经过 Q/K norm 与 RoPE 后的 Query 和 Key。Qwen3-8B 在本实验中有 36 层、每层 32 个 Query head、8 个 KV head，head dimension 为 $d_h = 128$ 。

Softmax 权重为：

$$a_{\ell hi} = \frac{\exp(s_{\ell hi})}{\sum_j \exp(s_{\ell hj})}.$$

该 head 分配给证据集合的总质量为：

$$M_{\ell h} = \sum_{e \in E} a_{\ell he}.$$

定义证据分数的 log-sum-exp：

$$N_{\ell h}^E = \text{logsumexp}_{e \in E}(s_{\ell he}),$$

以及全部历史 token 的 log-sum-exp：

$$D_{\ell h} = \text{logsumexp}_j(s_{\ell hj}).$$

则 evidence mass 满足精确关系：

$$\boxed{\log M_{\ell h} = N_{\ell h}^E - D_{\ell h}}.$$

因此，evidence mass 降低有两个直接来源：

- 证据自身的 QK 分数相对变弱，即 $N_{\ell h}^E$ 降低；
- 其他 token 的竞争增强，即 $D_{\ell h}$ 增大。

47 → 48 的观测

对最终证据 token，全层平均结果为：

指标	47	48	变化
Query norm	16.484	16.181	-1.84%
Key norm	30.176	30.175	-0.01%
QK cosine	0.1581	0.1491	-5.73%
QK score	4.849	4.453	-8.17%
全模型 evidence mass	1.4225%	1.1271%	-20.8%

与此同时，平均 softmax log-sum-exp 从 13.288 降到 12.877，并没有增大。因此这个局部转折不是由分母膨胀主导，而是证据 QK numerator 下降得比整体 denominator 更快。

在几个关键晚层 head 中，这个关系可以直接由

$$\Delta \log M_{\ell h} = \Delta N_{\ell h}^E - \Delta D_{\ell h}$$

验证：

Head	ΔN^E	ΔD	mass 变化
L31H30	-1.371	-1.164	-18.8%
L31H5	-1.943	-1.478	-37.2%
L33H11	-1.224	-0.886	-28.7%
L32H3	-1.885	-1.515	-30.9%

例如 L31H5：

$$\Delta \log M_{31,5} = -1.943 - (-1.478) = -0.465,$$

因此：

$$\frac{M_{48}}{M_{47}} = \exp(-0.465) \approx 0.628,$$

即 evidence mass 下降约 37.2%。

2. Evidence mass 如何改变 Value 读取

一个 attention head 的输出是 Value 的加权和：

$$\mathbf{o}_{\ell h} = \sum_i a_{\ell h i} \mathbf{v}_{\ell h i}.$$

将历史 token 分成证据集合 E 和非证据集合 B 。定义证据集合内部的条件平均 Value：

$$\bar{\mathbf{v}}_{\ell h}^E = \frac{1}{M_{\ell h}} \sum_{e \in E} a_{\ell h e} \mathbf{v}_{\ell h e},$$

以及背景 token 的条件平均 Value：

$$\bar{\mathbf{v}}_{\ell h}^B = \frac{1}{1 - M_{\ell h}} \sum_{i \in B} a_{\ell h i} \mathbf{v}_{\ell h i}.$$

attention 输出可以精确改写为：

$$\mathbf{o}_{\ell h} = M_{\ell h} \bar{\mathbf{v}}_{\ell h}^E + (1 - M_{\ell h}) \bar{\mathbf{v}}_{\ell h}^B.$$

这表明 evidence mass 是证据 Value 和背景 Value 之间的混合系数。因为所有 attention 权重之和必须为 1，证据 mass 减少的部分一定会重新分配给非证据 token。

如果暂时固定两类 Value 的条件方向，则：

$$\frac{\partial \mathbf{o}_{\ell h}}{\partial M_{\ell h}} = \bar{\mathbf{v}}_{\ell h}^E - \bar{\mathbf{v}}_{\ell h}^B.$$

小的 mass 变化产生：

$$\Delta \mathbf{o}_{\ell h} \approx \Delta M_{\ell h} \left(\bar{\mathbf{v}}_{\ell h}^E - \bar{\mathbf{v}}_{\ell h}^B \right).$$

因此，mass 降低同时意味着：

1. 证据 Value 的系数减小；
2. filler、问题文本、格式 token 等背景 Value 的系数增大。

它并不是单纯“少读一点证据”，而是把 attention 输出向量从证据方向推向背景方向。

3. Head 输出如何写入 residual stream

各个 head 的输出经过 W_O 合并：

$$\Delta \mathbf{x}_\ell^{\text{attn}} = \sum_h W_{O,\ell h} \mathbf{o}_{\ell h}.$$

由 evidence mass 变化造成的 residual 改变量近似为：

$$\Delta \mathbf{x}_\ell^E \approx \sum_h \Delta M_{\ell h} W_{O,\ell h} \left(\bar{\mathbf{v}}_{\ell h}^E - \bar{\mathbf{v}}_{\ell h}^B \right).$$

这一步说明：相同幅度的 evidence mass，在不同 head 中不一定产生相同作用。决定作用方向的是：

$$W_{O,\ell h} \left(\bar{\mathbf{v}}_{\ell h}^E - \bar{\mathbf{v}}_{\ell h}^B \right).$$

如果该方向编码最终答案、两跳连接或答案复制，它会支持正确输出；如果该 head 主要编码句法、格式或中间状态，mass 变化对最终答案可能较弱，甚至方向相反。

这解释了两个实验现象：

- 全模型 evidence mass 与完整词表 margin 的相关系数为 $r = 0.795$ ；
- L30--33 evidence mass 与完整词表 margin 的相关系数提高到 $r = 0.920$ 。

同时，部分 head 的 mass 与答案 margin 呈负相关，因此不能把所有 head 的 attention mass 当成等价证据信号。

4. 证据信号如何通过后续层传播

设从第 ℓ 层到最终层的网络变换为：

$$\mathbf{x}_L = F_{\ell \rightarrow L}(\mathbf{x}_\ell).$$

对局部变化进行一阶展开：

$$\Delta \mathbf{x}_L \approx J_{\ell \rightarrow L} \Delta \mathbf{x}_\ell^E,$$

其中：

$$J_{\ell \rightarrow L} = \frac{\partial \mathbf{x}_L}{\partial \mathbf{x}_\ell}$$

代表后续 attention、MLP、RMSNorm 和 residual connection 对该信号的联合变换。

代入上一节：

$$\Delta \mathbf{x}_L \approx \sum_{\ell, h} J_{\ell \rightarrow L} W_{O,\ell h} \left(\bar{\mathbf{v}}_{\ell h}^E - \bar{\mathbf{v}}_{\ell h}^B \right) \Delta M_{\ell h}.$$

晚层 head 更重要的原因是：

- 它们距离 LM head 更近；
- 证据信号不需要穿过很多次非线性变换；

- 后面没有足够层数重新检索或修复证据；
- 它们写入的 residual 方向更容易直接改变输出 logits。

47 → 48 时，多个与答案 margin 高相关的晚层 head 同时下降：

Head	evidence mass 变化
L31H5	−37.2%
L32H3	−30.9%
L33H11	−28.7%
L31H30	−18.8%
L33H16	−16.7%

因此，输出翻转不是所有 head 均匀地少读一点证据，而是若干晚层关键通路同时减弱。

5. 最终 residual 如何改变答案 margin

最终 hidden state 经过 RMSNorm 和 LM head 后得到 token t 的 logit：

$$z_t = \mathbf{w}_t^\top \text{RMSNorm}(\mathbf{x}_L) + b_t.$$

对正确答案 $g = \text{basket}$ 和竞争 token $c = \text{Let}$ ，定义完整词表 margin：

$$m_{g,c} = z_g - z_c.$$

由于 softmax 的公共分母相消：

$$m_{g,c} = \log p(g) - \log p(c).$$

最终 residual 的变化对 margin 的一阶影响为：

$$\Delta m_{g,c} \approx (\mathbf{w}_g - \mathbf{w}_c)^\top J_{\text{norm}} \Delta \mathbf{x}_L.$$

继续代入前面的 residual 传播式：

$$\Delta m_{g,c} \approx \sum_{\ell,h} \kappa_{\ell h}^{g,c} \Delta M_{\ell h},$$

其中：

$$\kappa_{\ell h}^{g,c} = (\mathbf{w}_g - \mathbf{w}_c)^\top J_{\text{norm}} J_{\ell \rightarrow L} W_{O,\ell h} (\bar{\mathbf{v}}_{\ell h}^E - \bar{\mathbf{v}}_{\ell h}^B).$$

$\kappa_{\ell h}^{g,c}$ 的含义是：

第 ℓ 层第 h 个 head 的一单位 evidence mass，最终能够给 **basket** 相对 **Let** 的 margin 带来多少贡献。

因此，真正决定答案 margin 的不是未加权的总 mass：

$$\sum_{\ell,h} M_{\ell h},$$

而是功能加权后的证据信号：

$$\sum_{\ell,h} \kappa_{\ell h}^{g,c} M_{\ell h}.$$

6. 将 47 → 48 的实验结果代入

L30--33 的 evidence mass 为：

$$M_{47} = 0.028269, \quad M_{48} = 0.023221.$$

所以：

$$\Delta M = M_{48} - M_{47} = -0.005047,$$

即下降 0.5047 个百分点。

在完整 34--100 token 扫描中，描述性线性关系为：

$$m_{\text{basket,Let}} \approx -7.302 + 298.64M_{\text{L30--33}}.$$

换成百分点，L30--33 evidence mass 每增加一个百分点，margin 平均增加约：

$$\frac{\Delta m}{\Delta M_{\text{百分点}}} \approx 2.986.$$

因此，由本次 mass 变化预测的 margin 下降为：

$$\widehat{\Delta m} = 2.986 \times (-0.5047) \approx -1.507.$$

实际观察到：

$$\Delta m_{\text{actual}} = -1.922.$$

在该样例内部，简单的晚层 mass 线性关系能够描述实际 margin 变化的约：

$$\frac{1.507}{1.922} \approx 78.4\%.$$

剩余变化可能来自 Value 方向本身的变化、非证据 Value 的组成变化、其他层和 head、MLP 非线性，以及竞争输出模式的增强。该 78.4% 是同一样例内的描述性分解，不应解释成严格的因果贡献率。

输出端的精确分解

47 token 时：

$$p_{47}(\text{basket}) = 0.4534, \quad p_{47}(\text{Let}) = 0.0764.$$

48 token 时：

$$p_{48}(\text{basket}) = 0.1845, \quad p_{48}(\text{Let}) = 0.2124.$$

因此：

$$\Delta \log p(\text{basket}) = \log \frac{0.1845}{0.4534} = -0.899,$$

$$\Delta \log p(\text{Let}) = \log \frac{0.2124}{0.0764} = +1.023.$$

最终 margin 变化为：

$$\Delta m = -0.899 - 1.023 = -1.922.$$

所以输出翻转由两部分共同构成：

1. 正确答案 `basket` 的 residual 支持减弱；
2. 通用生成前缀 `Let` 的 residual 支持增强。

最终：

$$m_{\text{basket,Let}} : +1.781 \longrightarrow -0.141,$$

margin 穿过零点，完整词表 greedy 首 token 随之翻转。

7. 证据强度与下一步因果验证

当前实验已经直接保存和测量：

1. QK score、cosine、norm;
2. 每层每个 head 的 evidence attention mass;
3. softmax log-sum-exp;
4. 最终词表概率、margin 与 PPL。

因此下面两段已由数据直接支持：

QK 变化 $\longrightarrow$ evidence mass 变化,

最终 logits $\longrightarrow$ margin、概率与 PPL 变化.

尚未完整保存的是：

Value $\longrightarrow W_O \longrightarrow$ residual stream $\longrightarrow$ LM head.

因此，从 mass 到 margin 的中间链条目前由模型公式、层/head 相关性和输出变化共同支持，但仍需要干预实验确认严格因果关系。

最直接的验证方法是在长度 48 的样本上，只恢复 L30--33 关键 head 的 evidence mass：

$$0.023221 \longrightarrow 0.028269,$$

同时保持长度 48 自己的 Value、MLP 和其他 head 不变，并按比例缩放非证据 attention，使每个 head 的权重和仍为 1。

根据当前线性关系，预期 margin 恢复：

$$\Delta m_{\text{predicted}} \approx +1.507,$$

即：

$$-0.141 \longrightarrow \text{约} +1.366.$$

如果真实干预后 `basket` 重新超过 `Let`，就可以把：

evidence mass 下降 $\longrightarrow$ 输出 margin 下降

从强机制关联提升为严格的因果证据。