

长上下文局部推理失败：最终综合结论

日期：2026-07-10

科学问题：如果真实世界中大量推理/决策本身是短程、低阶、局部可组合的，那么为什么小模型在长 `context` 推理中仍然会失败？

核心假设：复杂推理不一定是每一步都要同时聚合几十上百个条件，更可能是：每一步只依赖少数几个条件，推出一个新条件。复杂性主要来自很多局部 `step` 的连续组合，而不是单步推理本身很复杂。

即：Needle in the haystack 这类问题到底难在哪里？

难点可能不是短程关系本身，而是长 `context` 中的检索、筛选、抗干扰、变量绑定或中间状态维护。但这些目前都只是可能解释，需要实验验证。

子问题 1：什么 `workload` 对小模型是难的？

构造任务，使得：

- * 小模型在干净短 `context` 中能做对；
- * 同样的短程关系放进长 `context` 后会失败；
- * 长 `context` 中可以加入无关信息、相似干扰、冲突规则、多条推理链等。

子问题 2：训练时 `context` 长度和模型大小有什么影响？

更大的模型在长 `context` 训练里到底提升了什么？

子问题 3：推理时为什么会失败？

在 `inference` 阶段，把简单短程依赖，例如 “if A then B”，放进越来越长、越来越复杂的 `context`。

控制变量包括：

- * `context length`；
- * 干扰信息数量；
- * 干扰信息相似度；
- * 相关信息之间的距离；
- * 相关信息的位置；
- * 推理链长度；
- * 竞争推理链数量。

目标是画出不同模型的失败边界：

小模型在什么 `context` 长度和干扰强度下开始 `fail`? `fail` 时，有什么表现？例如 `attention selectivity` 变差，或者别的现象？

0. 当前结论

1. **Context 长度会影响模型推理时的 PPL / margin，但是不影响模型选出正确答案。**
2. **多个证据在文本中的分散程度不会影响模型的推理性能。**
3. **造成模型推理性能下降的主要原因是存在干扰或者冲突证据。**
4. **8B模型相对于0.6B模型的优势在于抗干扰能力更强。**
5. **模型推理能力下降，往往伴随着 gold-rule attention selectivity 下降。**

1. 总结答案

当前实验支持下面这个结论：

小模型在长 context 中失败，不是因为它不会做短程、低阶、局部规则。

在干净条件下，Qwen3-0.6B 可以稳定完成 if A then B 以及少步规则组合，甚至到 64k candidate scoring 仍然很高。

真正困难的是：在长文本中找到正确证据、抑制相似/冲突证据、把问题变量绑定到正确链，并在多步组合中维护中间状态。

当 high-similarity distractor、conflict rule 或 competitor chain 出现时，gold 的 margin 和 attention selectivity 会明显下降，错误候选会接近甚至超过正确候选。

因此，更准确的表述不是：


文本越长，所以模型推理能力越差。

而是：

长文本增加了证据选择、抗干扰和变量绑定压力；当文本中存在相似或竞争型干扰时，小模型更容易选错证据，于是表现为长 context 推理失败。


2. 关键图

2.1 Clean length




无干扰、无竞争链时，0.6B 到 64k 的 candidate accuracy 仍然很高；但 margin 随长度变长明显变薄。

2.2 Clean gap



无干扰、无竞争链时，相关 rule 之间 gap 从 0 到 8192 tokens 没有造成失败。


2.3 Interference boundary



low-sim 普通干扰基本可控；high/conflict 干扰和 competitor chain 会明显降低 accuracy。干扰数量不是简单单调变量，结构更重要。


模型失败主要不是因为 context 变长本身，而是因为长文本里出现了相似干扰、冲突证据或竞争推理链，导致模型选错证据或绑定到错误链。

2.4 Model size



8B 相比 0.6B 的主要提升出现在 high/conflict 和 competitor 条件下，说明更大模型主要提升抗干扰、候选排序和变量绑定。

2.5 Attention selectivity



competitor chain 出现后, gold-rule attention selectivity 明显下降。失败样本不是局部规则不会推, 而是没有稳定选中正确规则链。

3. 对三个子问题的回答

子问题 1: 什么 workload 对小模型是难的?

当前结果显示, 对小模型困难的不是干净局部规则, 而是下面几类 workload:

1. 有 high-similarity distractor 的规则检索;
2. 有 conflict rule 的规则筛选;
3. 有多条 competitor chain, 需要把 start code 绑定到正确链;
4. 多步 chain length 增加后, 需要维护中间状态;
5. 自然语言事实 needle, 尤其中文事实/中文问题在 64k/128k 下 evidence mass 会明显下降。

证据:

```
0.6B c1ean length:
1k=1.00, 4k=1.00, 8k=1.00, 16k=0.8889, 32k=0.9444, 64k=1.00

0.6B c1ean gap:
8k/32k 下 rule gap 0..8192, candidate acc 全部 1.00

0.6B interference:
8k, competitor=0, low = 1.00
8k, competitor=0, high/conflict = 0.55/0.45
8k, competitor=4, high/conflict = 0.50/0.40
32k, competitor=4, high/conflict = 0.45/0.60
```

所以 workload 设计上应该把“长度”和“干扰结构”分开控制。只加普通 filler 不一定难; 加入相似、冲突、竞争链才会暴露失败。

数据如何构造

每个样本由三部分组成：

```
[filler tokens + gold rules + distractor / competitor rules]
```

```
Task: Follow symbolic rules exactly.  
Use only lines beginning with VERIFIED RULE.  
Ignore DECOY RULE and NOTE lines even if they look similar.  
Start code: {start_code}  
Apply exactly {chain_length} valid rule step(s).  
What is the final active code?  
Answer:
```

目标规则链是 gold evidence。例如：

```
Start code: LA61-822  
  
VERIFIED RULE T0: IF LA61-822 IS ACTIVE THEN LB71-739 BECOMES ACTIVE.  
VERIFIED RULE T1: IF LB71-739 IS ACTIVE THEN LC38-299 BECOMES ACTIVE.  
VERIFIED RULE T2: IF LC38-299 IS ACTIVE THEN LD38-299 BECOMES ACTIVE.  
  
Gold answer: LD38-299
```

干扰项和竞争链的关系：

```
distractor 是局部干扰，通常是一条或多条不该用的规则/文本。  
competitor chain 是结构化干扰，是一整条看起来完整、合法、但起点不匹配的推理链。
```

也就是说，competitor chain 可以理解为更强的 distractor：它不是单条噪声，而是一条完整的错误候选链。

三类 distractor：

```
low distractor:  
NOTE L3: The catalog mentions code LX12-345, but this note is not an active rule.  
  
high-similarity distractor:  
VERIFIED RULE H7: IF LA61-823 IS ACTIVE THEN LB71-749 BECOMES ACTIVE.  
  
conflict rule:  
DECOY RULE X2: IF LA61-822 IS ACTIVE THEN LB99-111 BECOMES ACTIVE.
```

competitor chain 例子：

```
VERIFIED RULE C0: IF QA12-111 IS ACTIVE THEN QB22-222 BECOMES ACTIVE.  
VERIFIED RULE C1: IF QB22-222 IS ACTIVE THEN QC33-333 BECOMES ACTIVE.  
VERIFIED RULE C2: IF QC33-333 IS ACTIVE THEN QD44-444 BECOMES ACTIVE.
```

这条链本身格式正确，也是一条完整推理链；但它的起点是 QA12-111，不是问题里的 Start code: LA61-822，所以模型应该忽略它。

最后构造 candidate set：

正确答案: LD38-299
冲突答案: LB99-111
竞争链答案: QD44-444
随机错误 code: ...

如果 gold candidate 的 NLL 最低, 则 `candidate_correct = 1`; 否则为 0。

子问题 2: 训练时 context 长度和模型大小有什么影响?

模型大小部分可以初步回答:

8B 相比 0.6B 主要提升的是抗干扰、抗竞争链和变量绑定, 而不是 `clean local reasoning`。

公平 8k clean-interference 子集:

Qwen3-0.6B: 65.28%
Qwen3-8B: 87.50%

在 `competitor=4` 条件下:

0.6B: 58.33%
8B: 91.67%

在 `competitor=4 + high/conflict` 下:

0.6B: 41.67% / 41.67%
8B: 83.33% / 91.67%

这说明更大模型在长 context 中提升的核心不是“会不会做 if A then B”, 而是:

1. 更好地区分 gold rule 和相似干扰;
2. 更好地抑制 competitor chain;
3. 更稳定地把 start code 绑定到正确链;
4. 给正确候选更高相对概率。

训练时 context length 的因果效应目前不能严格回答。原因是我们没有 matched checkpoints:

same model size
same training data
same recipe
different training context length

本地 config 显示当前 Qwen3-0.6B 和 Qwen3-8B 都是:

```
max_position_embeddings = 40960
rope_theta = 1000000
rope_scaling = None
```

所以这轮只能回答模型大小, 不能把训练长度效应从模型大小和训练数据差异中隔离出来。

子问题 3：推理时为什么会失败？

这个子问题要回答的不是“模型会不会做 if A then B”，而是：

在 `inference` 阶段，把简单短程依赖，例如 `if A then B`，放进越来越长、越来越复杂的 `context` 后，
模型会在什么条件下从能答对变成答错？

因此实验设计要系统控制下面这些变量：

1. context length;
2. 干扰信息数量;
3. 干扰信息相似度;
4. 相关信息之间的距离;
5. 相关信息在 context 中的位置;
6. 推理链长度;
7. 竞争推理链数量。

目标是画出不同模型的 inference failure boundary:

小模型在什么 `context` 长度、什么干扰强度、什么竞争链密度下开始 `fail`?
大模型的边界是否更靠后?
`fail` 的时候，模型内部和输出上有什么可观测表现？

当前结果显示，失败更像是证据选择、抗干扰和变量绑定失败，而不是简单规则本身不会推。具体表现为：

1. gold candidate margin 下降到接近 0 或负数;
2. gold-rule attention selectivity 下降;
3. 模型把概率分配给 conflict / competitor / distractor 产生的错误 code;
4. 自由生成时出现 miss、格式错误、或先答错再补正确答案。

最直接证据：

0.6B 8k interference:
competitor=0: mean selectivity 0.3518
competitor=4: mean selectivity 0.0901

32k interference:
competitor=0: mean margin 1.2873
competitor=4: mean margin 0.0015

这说明加入竞争链以后，模型并不是“推理步骤算错”，而是正确链的证据优势被压掉了。

所以子问题 3 的核心结论应写成：

推理失败不是由单一 `context length` 决定的，而是由 `context length`、干扰强度、干扰相似度、相关证据位置、相关证据距离、推理链长度和竞争链数量共同决定。

当 `context` 变长但没有强干扰时，小模型仍然可以做对简单短程规则；
当高相似干扰、冲突规则或竞争推理链出现时，`gold evidence` 的 `attention selectivity` 和 `candidate margin` 会下降，
模型更容易把问题绑定到错误证据链，从而 `fail`。

4. 与年龄 needle 实验的统一解释

年龄 needle 结果：

1. `zh prompt + zh filler` 在 64k 前/中部失败，128k 全部失败；
2. `zh prompt + en filler` 到 64k 很强，但 128k 失败；
3. `en prompt + en filler` 在 128k seed0 三个位置都成功；
4. 中文 128k 下 `evidence mass` 会掉到很低。

local-rule clean ablation 结果：

1. 英文符号规则、`candidate scoring`、无干扰时，0.6B 到 64k 仍然稳；
2. gap 0.8192 不造成失败；
3. `high/conflict/competitor` 一出现，准确率、`margin`、`selectivity` 明显下降。

统一解释：

`Needle-in-the-haystack` 的难点不是单一的 `context length`。
它取决于 `language`、`task format`、`scoring/decoding method`、`position`、`RoPE` 外推、干扰结构和变量绑定压力。

中文年龄 `needle` 的 128k 失败更像自然语言事实检索和 `attention mass` 崩塌；
`local-rule` 的失败更像相似规则/竞争链造成的证据筛选和绑定错误。

5. 现在可以写进论文/汇报的结论

推荐表述：

Our results do not support the simple view that long-context reasoning fails because local reasoning itself becomes hard.
In clean contexts, Qwen3-0.6B can solve local symbolic rules and their short compositions even at long lengths.
The failure boundary emerges when long contexts contain similar, conflicting, or competing evidence.
These distractors reduce gold-evidence selectivity and shrink the probability margin of the correct candidate,
causing the model to bind the query to a wrong chain.
Larger models mainly improve this evidence selection and binding robustness, rather than the clean local rule itself.

中文版本：

实验结果不支持“长上下文直接削弱局部推理能力”的简单解释。

在干净上下文中，Qwen3-0.6B 可以稳定完成短程规则及其局部组合。

真正的失败边界出现在长文本包含相似、冲突或竞争型证据时。

这些干扰会降低 gold evidence 的 attention selectivity，压缩正确候选的概率 margin，使模型把问题绑定到错误规则链。

更大模型主要提升的是证据筛选、抗干扰和变量绑定鲁棒性，而不是干净局部规则本身。

6. 仍未严格回答的部分

唯一没有被严格因果识别的是：

训练时 context length 到底提升了什么？

原因是当前没有 matched training-context checkpoints。要严格回答，需要同一模型大小、同一训练配方、不同训练上下文长度的 checkpoint。

可行后续实验：

1. 找或训练 matched 0.6B checkpoints，例如 4k/16k/32k/64k context training；
2. 对这些 checkpoint 跑同一套 clean length/interference/gap；
3. 看训练长度主要提升 clean retrieval、RoPE 外推、还是 interference robustness。

在没有 matched checkpoints 前，当前最可靠结论是：

模型大小提升了抗干扰和绑定能力；训练长度效应不能单独归因。