

RoPE 对长程检索的影响：第一层相位、跨层累计与改进方案

模型：Qwen3-8B；理论与文献核对日期：2026-07-30。

核心问题：为什么只在证据与问题之间增加少量文本，就可能使正确证据的 QK、attention mass 和最终答案概率大幅下降？

阅读结构

本文严格按照四个研究问题组织：

- 第一层**：正确证据的 RoPE QK 如何随相对位置相位变化；
- 第 N 层到第 $N + 1$ 层**：第一层扰动如何经 attention、Value、residual 和 MLP 逐层累计；
- 近期工作**：已有长上下文 RoPE 方法解决了什么，还缺少什么；
- Final**：设计面向远程证据检索的 SAGE-RoPE，并与 exact post-RoPE Top-2% 比较。

公式推导和方案设计位于前四节；GPU7 实验支撑、限制和复现路径放在后面。

结论先行

RoPE 对远程证据的影响不是简单的“距离越远，分数必然越低”，而是：

- 第一层中，增加文本会改变 Query 与固定证据 Key 的相对相位；每个二维频率对的贡献随距离周期性增减。
- 第一层产生的小扰动会先改变 softmax 权重和 Value 写入，再经过后续层的 Q/K/V、attention、MLP 和残差连接继续传播。
- 因而，后层看到的已经不只是“同一个 Query 加了不同 RoPE”，而是内容向量本身也变了，即 pre-RoPE Query 漂移。
- 长程检索需要将“近程顺序”与“远程语义相关性”拆开处理。直接把所有位置编码关闭，或完全采用 pre-RoPE 分数，都不稳定。
- 独立 seeds 4-7 中，SAGE 25% 相比 exact post-RoPE Top-2%，在 32K 将 Gold PPL 从 15.382 降至 3.806，在 64K 将最佳 Gold PPL 从 4.321 降至 3.625；但逐样例胜率仍只有 50%，因此目前属于有效的长程机制原型，不是已经全面取代 exact Top-2% 的最终系统。

本文提出的候选方案是 **SAGE-RoPE: Semantic-Adaptive Gated Evidence RoPE**：

- 近程 token：保留标准 RoPE；
- 远程 token：用 pre-RoPE 语义分数召回；
- 每层每个 head 校准语义分数尺度；
- 将校准后的语义分数与原 post-RoPE 分数连续融合，而不是硬切换；
- 只让少量远程候选进入 softmax，避免长尾分母重新淹没证据；
- 检索到证据块后，以块为单位进行位置修复，保留块内顺序。

1. 第一层：RoPE 怎样改变 QK 分数

1.1 相对距离与频率

设 Query 位于位置 t ，正确证据 Key 位于位置 p 。定义 Query 相对证据的距离：

$$\Delta = t - p.$$

其中：

- t : Query 所在位置；
- p : 证据 Key 所在位置；
- Δ : Query 相对证据的距离。

例如，证据在第 100 个 token，问题 token 在第 1000 个 token，则：

$$\Delta = 1000 - 100 = 900.$$

RoPE 将一个 head 的 hidden dimension 两两组成二维平面。第 i 个二维平面的旋转角速度为：

$$\omega_i = \theta^{-2i/d}, \quad i = 0, \dots, \frac{d}{2} - 1.$$

Qwen3-8B 中：

$$d = 128, \quad \theta = 10^6, \quad i = 0, \dots, 63.$$

因此，一个 head 的 128 个维度被组成 64 个二维旋转对：

- 小 i 时， ω_i 较大，旋转快，属于高频；
- 大 i 时， ω_i 较小，旋转慢，属于低频；
- 相对距离增加 Δ 后，第 i 对累积的位置相位为 $\Delta\omega_i$ 。

这里的 $\omega_i = \theta^{-2i/d}$ 是标准 RoPE 的基础频率。若推理时使用 YaRN 等缩放方法，还需要将它替换为模型实际使用的有效频率；第 1.6 节会给出此前边界实验中的有效周期。

1.2 为什么只剩“相对位置”

记未旋转的 Query 和 Key 为 q, k ，位置 x 对应的分块旋转矩阵为 R_x 。标准 RoPE QK 分数为：

$$s(t, p) = \frac{1}{\sqrt{d}} (R_t q)^\top (R_p k).$$

因为旋转矩阵满足：

$$R_t^\top = R_{-t}, \quad R_a R_b = R_{a+b},$$

所以：

$$R_t^\top R_p = R_{-t} R_p = R_{p-t}.$$

代回 QK 分数：

$$\begin{aligned}
s(t, p) &= \frac{1}{\sqrt{d}} q^\top R_t^\top R_p k \\
&= \frac{1}{\sqrt{d}} q^\top R_{p-t} k \\
&= \frac{1}{\sqrt{d}} q^\top R_{-\Delta} k.
\end{aligned}$$

因此，两个绝对位置 t, p 被合并成相对差：

$$p - t = -\Delta.$$

这就是 RoPE 的关键性质：注意力并不直接记住“第 100 位”和“第 1000 位”，而是主要通过二者相差 900 个 token 所对应的相对旋转关系工作。

1.3 单个二维频率对的精确展开

取第 i 个二维对：

$$q_i = \begin{bmatrix} q_{i,x} \\ q_{i,y} \end{bmatrix}, \quad k_i = \begin{bmatrix} k_{i,x} \\ k_{i,y} \end{bmatrix}.$$

令：

$$\alpha_i = \Delta \omega_i.$$

按照本文采用的旋转矩阵约定：

$$R(-\alpha_i) = \begin{bmatrix} \cos \alpha_i & \sin \alpha_i \\ -\sin \alpha_i & \cos \alpha_i \end{bmatrix}.$$

这一二维对未经 $1/\sqrt{d}$ 缩放的 QK 贡献为：

$$s_i(\Delta) = q_i^\top R(-\alpha_i) k_i.$$

直接展开：

$$\begin{aligned}
s_i(\Delta) &= q_{i,x} (k_{i,x} \cos \alpha_i + k_{i,y} \sin \alpha_i) \\
&\quad + q_{i,y} (-k_{i,x} \sin \alpha_i + k_{i,y} \cos \alpha_i) \\
&= (q_{i,x} k_{i,x} + q_{i,y} k_{i,y}) \cos \alpha_i \\
&\quad + (q_{i,x} k_{i,y} - q_{i,y} k_{i,x}) \sin \alpha_i.
\end{aligned}$$

定义：

$$A_i = q_{i,x} k_{i,x} + q_{i,y} k_{i,y},$$

$$B_i = q_{i,x} k_{i,y} - q_{i,y} k_{i,x}.$$

其中：

- A_i 是普通二维点积，表示 Query 与 Key 在该二维平面上的同方向相似性；
- B_i 是二维叉积的有向版本，表示二者在该平面上的方向错位。

于是：

$$s_i(\Delta) = A_i \cos(\Delta \omega_i) + B_i \sin(\Delta \omega_i).$$

完整的一个 head 的 QK logit 是 64 个二维对贡献之和，再乘以缩放因子：

$$s(t, p) = \frac{1}{\sqrt{d}} \sum_{i=0}^{d/2-1} s_i(\Delta).$$

因此，一个远程证据的 QK 分数并不是由单一的“距离衰减函数”决定，而是由 64 个不同频率、不同内容系数的振荡项叠加得到。

1.4 改写成“振幅 + 相位”

定义：

$$\rho_i = \sqrt{A_i^2 + B_i^2}, \quad \psi_i = \text{atan2}(B_i, A_i).$$

这相当于将二维向量 (A_i, B_i) 写成极坐标：

$$A_i = \rho_i \cos \psi_i, \quad B_i = \rho_i \sin \psi_i.$$

代入上一节：

$$\begin{aligned} s_i(\Delta) &= \rho_i \cos \psi_i \cos(\Delta \omega_i) + \rho_i \sin \psi_i \sin(\Delta \omega_i) \\ &= \rho_i \cos(\Delta \omega_i - \psi_i). \end{aligned}$$

即：

$$s_i(\Delta) = \rho_i \cos(\Delta \omega_i - \psi_i).$$

这个形式可以直接解释每个量的作用：

- ρ_i ：该二维对最多能够贡献多大的 QK 分数；
- ψ_i ：当前 Query 与 Key 的内容向量本身偏好的相位；
- $\Delta \omega_i$ ：相对位置带来的相位；
- $\Delta \omega_i - \psi_i$ ：内容偏好与位置旋转之间的失配量。

当二者接近时：

$$\Delta \omega_i - \psi_i \approx 0,$$

余弦接近 1，该频率对产生较大的正贡献。当相差接近 π 时：

$$\Delta \omega_i - \psi_i \approx \pi,$$

余弦接近 -1 ，即使 Key 的内容确实是正确证据，该频率对也可能产生较大的负贡献。

所以，“证据语义正确”并不等于“RoPE 后它必然得到正向加成”。内容决定 ρ_i, ψ_i ，位置决定 $\Delta \omega_i$ ，最终 QK 是两者共同作用的结果。

1.5 插入 m 个 filler token 后发生什么

保持证据位置不变，在证据与 Query 之间插入 m 个 filler token，使 Query 向后移动：

$$\Delta' = \Delta + m.$$

第 i 个二维对的分数变化为：

$$\delta s_i = s_i(\Delta + m) - s_i(\Delta).$$

直接代入：

$$\begin{aligned}\delta s_i &= A_i [\cos((\Delta + m)\omega_i) - \cos(\Delta\omega_i)] \\ &\quad + B_i [\sin((\Delta + m)\omega_i) - \sin(\Delta\omega_i)].\end{aligned}$$

使用三角恒等式：

$$\cos x - \cos y = -2 \sin\left(\frac{x+y}{2}\right) \sin\left(\frac{x-y}{2}\right),$$

$$\sin x - \sin y = 2 \cos\left(\frac{x+y}{2}\right) \sin\left(\frac{x-y}{2}\right),$$

得到精确变化式：

$$\delta s_i = 2 \sin\left(\frac{m\omega_i}{2}\right) \left[-A_i \sin\left(\frac{(2\Delta + m)\omega_i}{2}\right) + B_i \cos\left(\frac{(2\Delta + m)\omega_i}{2}\right) \right].$$

这个式子包含两部分。外部因子

$$\sin\left(\frac{m\omega_i}{2}\right)$$

表示插入 m 个 token 后产生了多大的相位增量；方括号中的内容—相位耦合项，则决定在当前 A_i, B_i 和当前相位下，这次变化最终是增益还是损失。

因此，分数并不会随距离单调下降，而是可能下降、恢复甚至反复穿过零点。

因为：

$$|-A_i \sin x + B_i \cos x| \leq \sqrt{A_i^2 + B_i^2} = \rho_i,$$

所以有：

$$|\delta s_i| \leq 2\rho_i \left| \sin\left(\frac{m\omega_i}{2}\right) \right|.$$

对于完整的一个 head，插入 filler 前后的 QK logit 变化为：

$$\delta s_{\text{head}} = \frac{1}{\sqrt{d}} \sum_{i=0}^{d/2-1} \delta s_i.$$

利用三角不等式，可以得到一个保守上界：

$$|\delta s_{\text{head}}| \leq \frac{2}{\sqrt{d}} \sum_{i=0}^{d/2-1} \rho_i \left| \sin\left(\frac{m\omega_i}{2}\right) \right|.$$

但实际变化通常小于这个上界，因为不同频率对的 δs_i 可能一部分为正、一部分为负，彼此抵消。只有当若干个高能量频率对在同一长度区间内共同下降时，完整 head 的证据 QK 才会出现明显下跌。

该上界给出三个重要结论：

1. 高频对的 ω_i 较大，少量新增 token 就可能造成显著相位变化；
2. 但只有当 ρ_i 较大时，相位变化才会转化成显著 QK 变化；
3. 因此，不能只根据频率高低判断一个 head 负责局部信息还是远程信息，还必须观察该 head 在具体 Q/K 上学到的内容能量和相位。

对距离求导，可以得到当前位置的局部敏感度：

$$\frac{\partial s_i}{\partial \Delta} = \omega_i [-A_i \sin(\Delta\omega_i) + B_i \cos(\Delta\omega_i)].$$

它表示：在当前位置继续增加少量距离时，该二维对的 QK 分数会变化多快。局部敏感度同时受到三项控制：

- 频率 ω_i ；
- 当前距离对应的相位 $\Delta\omega_i$ ；
- 内容系数 A_i, B_i 。

这也解释了为什么同样增加 8K token，不同 head、不同证据甚至相邻长度点的 QK 变化都可能完全不同。

1.6 Qwen3-8B 的数值尺度

Qwen3-8B 原始 RoPE base 为 10^6 。在此前 140K 边界实验中，实际使用了 YaRN factor 4；以下是模型实际生成的部分有效频率：

二维对 i	有效周期	增加 64 token 的相位变化	距离 143,424 的相位
0	6.28	64.000 rad	143,424.0 rad
8	35.33	11.381 rad	25,504.8 rad
16	198.69	2.024 rad	4,535.5 rad
24	1,117.33	0.360 rad	806.5 rad
32	9,518.09	0.042 rad	94.7 rad
40	110,325.34	0.00364 rad	8.17 rad
48	715,290.38	0.00056 rad	1.26 rad
63	18,227,720.0	0.000022 rad	0.049 rad

因此，只增加 64 个 token：

- 对前若干高频和中频对已是明显旋转；
- 对低频对直接相位变化很小；
- 但第一层 attention 输出的改变会进入下一层，之后不再只是直接相位变化。

1.7 GPU7 上的第一层精确验证

在 Qwen3-8B、YaRN factor 2、NF4、seed 0 上，固定同一条证据和同一 Query token，只改变两者距离。第一层的 pre-RoPE Q 和 K 在四个长度下逐位完全相等：


$$\tilde{Q}_0(\Delta_1) = \tilde{Q}_0(\Delta_2), \quad \tilde{K}_0(\Delta_1) = \tilde{K}_0(\Delta_2).$$

它们的范数始终分别为 88.2608 和 915.2758。因此下面的第一层 QK 变化不可能来自内容向量漂移，只能来自 $\Delta\omega_i$ 的变化：

证据—Query 距离	32 个 head 的平均证据 QK	最小 QK	最大 QK	公式重构最大误差
7,996	-5.5876	-15.6637	3.3864	0.00063

证据—Query 距离	32 个 head 的平均证据 QK	最小 QK	最大 QK	公式重构最大误差
16,188	-4.8579	-14.2073	1.1108	0.00109
32,572	-13.4190	-26.6061	1.8319	0.00131
65,340	-33.5855	-66.4306	1.4269	0.00198

把 64 个二维对的
 $A_i \cos(\Delta\omega_i) + B_i \sin(\Delta\omega_i)$ 相加后，与显式旋转
Q/K 得到的分数最大只相差 0.00198，数值上验证了上述推导。



图中的四条频带线是为了可读性将 64 个二维对按频率平均分为四组，不是说 Qwen3-8B 只有四个频率。这个样例中，高、中频贡献发生振荡，最低频组在长距离处形成主要负贡献。第一层平均 QK 为负也不等于模型已经回答失败：许多真正承担证据读取的 head 位于后层；该实验的作用是严格隔离并验证第一步“纯相位扰动”。

2. 从第 N 层到第 $N + 1$ 层：扰动如何累计

2.1 精确的层更新

以 pre-norm Transformer 为例，第 l 层可写为：

$$u_l = h_l + \mathcal{A}_l(h_l; P),$$

$$h_{l+1} = u_l + \mathcal{M}_l(u_l),$$

其中：

- h_l 是进入该层的 residual;
- $\mathcal{A}_l$ 是 attention 分支;
- $\mathcal{M}_l$ 是 MLP 分支;
- P 表示位置及 RoPE 相位。

比较短序列 S 与增加 filler 后的长序列 T ，定义：

$$\delta h_l = h_{l,T} - h_{l,S}.$$

则精确差分为：

$$\delta h_{l+1} = \delta h_l + \delta \mathcal{A}_l + \delta \mathcal{M}_l.$$

这就是此前实验中“residual 输入差异 + attention 差异 + MLP 差异 = residual 输出差异”的来源。

2.2 QK 分数的三类扰动

第 l 层、证据位置 j 的分数为：

$$s_{l,j} = \frac{q_l^\top R_{\Delta_j} k_{l,j}}{\sqrt{d}}.$$

一阶展开：

$$\delta s_{l,j} \approx \frac{1}{\sqrt{d}} [\delta q_l^\top R_{\Delta_j} k_{l,j} + q_l^\top R_{\Delta_j} \delta k_{l,j} + q_l^\top \delta R_{\Delta_j} k_{l,j}].$$

三项分别代表：

1. Query 内容漂移;
2. Key 内容漂移;
3. 相对位置相位变化。

第一层最终 Query token 的输入 embedding 相同，因此最初的 δq_0 可以为零；但第三项先改变 attention。到后续层，前一层 Value 写入不同，第一项和第二项随即变为非零。

2.3 QK 如何变成 attention mass 变化

attention 权重为：

$$a_{l,j} = \frac{\exp(s_{l,j})}{\sum_r \exp(s_{l,r})}.$$

softmax 的 Jacobian 为：

$$\frac{\partial a_{l,j}}{\partial s_{l,k}} = a_{l,j} (\mathbf{1}[j = k] - a_{l,k}).$$

因此，正确证据 g 的一阶变化为：

$$\delta a_{l,g} \approx a_{l,g} \left(\delta s_{l,g} - \sum_j a_{l,j} \delta s_{l,j} \right).$$

也就是说，关键不只是证据分数是否下降，而是：

$$\delta s_{l,g} < \sum_j a_{l,j} \delta s_{l,j}$$

时，证据相对于竞争者的 attention mass 才会下降。

2.4 attention mass 如何改变下一层 Query

attention 输出为：

$$o_l = W_{O,l} \sum_j a_{l,j} v_{l,j}.$$

其一阶变化为：

$$\delta o_l \approx W_{O,l} \left[\sum_j \delta a_{l,j} v_{l,j} + \sum_j a_{l,j} \delta v_{l,j} \right].$$

第一项表示“写入哪些 token 变了”，第二项表示“被写入的 Value 本身变了”。

随后：

$$\delta h_{l+1} \approx \delta h_l + \delta o_l + J_{\mathcal{M}_l} (\delta h_l + \delta o_l).$$

下一层的 pre-RoPE Query 因而变成：

$$\delta q_{l+1}^{\text{pre}} \approx J_{Q,l+1} \delta h_{l+1}.$$

这就是从“第一层只发生相位变化”逐步变成“后层 pre-RoPE Query 内容漂移”的完整链条。

2.5 多层累计形式

将一层的局部 Jacobian 记为 J_l ，该层由位置直接注入的扰动记为 b_l ，则：

$$\delta h_{l+1} \approx J_l \delta h_l + b_l.$$

递推到第 L 层：

$$\delta h_L \approx \sum_{l=0}^{L-1} \left(\prod_{r=l+1}^{L-1} J_r \right) b_l.$$

因此，小扰动是否被放大，取决于后续 Jacobian 乘积在该扰动方向上的增益，而不只取决于单层 RoPE 的旋转幅度。

最终正确答案与竞争答案的 margin 为：

$$\Delta_{\text{out}} = (W_{\text{gold}} - W_{\text{comp}})^\top h_L.$$

其变化为：

$$\delta \Delta_{\text{out}} = (W_{\text{gold}} - W_{\text{comp}})^\top \delta h_L.$$

当该量使 margin 穿过 0，首 token 的赢家就会切换。

2.6 现有 143,424 → 143,488 实验证据

层	residual 输出绝对差异	pre-RoPE Q 相对差异	Q cosine
L0	1.466	0.000	1.000
L19	11.574	0.103	0.995
L20	15.976	0.120	0.993
L21	23.128	0.190	0.982
L22	35.106	0.217	0.976
L23	47.462	0.340	0.941
L24	59.158	0.350	0.937

表中比较的是 143,424-token 条件 S 和 143,488-token 条件 T
下同一个最终 Query token。三个量分别定义为：

$$D_{\text{res},l} = \|h_{l,T}^{\text{out}} - h_{l,S}^{\text{out}}\|_2,$$
$$D_{Q,l}^{\text{rel}} = \frac{\|\tilde{Q}_{l,T} - \tilde{Q}_{l,S}\|_F}{\|\tilde{Q}_{l,S}\|_F},$$
$$C_{Q,l} = \frac{\langle \tilde{Q}_{l,T}, \tilde{Q}_{l,S} \rangle}{\|\tilde{Q}_{l,T}\|_F \|\tilde{Q}_{l,S}\|_F}.$$

其中 residual 是 4096 维层输出； $\tilde{Q}_l$ 是 RoPE 前 32×128 的全部 Query heads。Residual 一列是绝对 L2 距离，而 pre-RoPE Q 一列除了短序列 Q 的范数；所以 0.103 表示扰动范数约为原 Q 范数的 10.3%，11.574 则不是百分比。

该表与推导一致：

- L0 的 pre-RoPE Q 完全相同；
- L0 residual 输出已不同，说明直接 RoPE/attention 扰动已经写入；
- 差异随后逐层累计；
- 到 L20-L24，pre-RoPE Q 本身发生显著漂移。

3. 近期相关工作

3.1 主要路线

工作	核心方法	对本项目的启发与不足
Position Interpolation, 2023	将位置线性压回训练范围，并进行少量微调	减少 OOD 相位，但所有远程位置统一压缩，未直接分离顺序与语义

工作	核心方法	对本项目的启发与不足
YaRN, ICLR 2024	分频率插值并修正 attention temperature	Qwen3 长上下文的直接基础；仍然保留所有远程 token 的周期相位
LM-Infinite, NAACL 2024	限制远程有效距离并使用特殊稀疏 mask	证明“不要让模型看到任意大的相对距离”有效，但远程 token 的区分能力有限
SelfExtend, ICML 2024	近程 neighbor attention + 远程 grouped attention	与“近程保序、远程降分辨率”高度一致；分组规则与语义相关性仍是分开的
Resonance RoPE, ACL Findings 2024	调整波长，使训练范围和外推位置更一致	缓解位置 OOD，但没有直接消除远程相位对语义排序的翻转
Why Does Effective Context Length Fall Short?, 2024	指出训练中相对位置分布左偏，提出 STRING 平移有效位置	支持“标称上下文长度不等于真正训练充分的距离”
LongRoPE2, ICML 2025	以 needle PPL 搜索逐维缩放，并混合长短上下文训练	说明不同维度需要不同处理；需要搜索和继续训练
RNoPE, 2025	交替使用 RoPE 层和 NoPE 层，并结合局部/全局 attention	强证据支持“全局语义不必每层携带 RoPE”；它是从训练开始设计的固定层间混合
HoPE, ACL 2025	将部分 RoPE 分量改成位置无关分量，只保留指定的高频旋转	与“位置子空间/内容子空间分离”直接相关；主要在从头训练的 3B 以内模型验证
HARPE, COLING 2025	不同 head 使用不同 RoPE base	支持 head-adaptive 设计；仍主要依赖固定的逐 head 频率与长上下文继续训练
RoPE Dimension Inefficiency, ACL Findings 2025	发现大范围旋转使部分维度难以用于长程检索	支持按 head/维度选择位置强度，而不是所有维度共享一个策略
Understanding RoPE Extensions, COLING 2025	从 attention 角度比较扩展方法	保持训练长度内的 attention pattern、降低 attention uncertainty 与检索正确率密切相关
LaMPE, ACL Findings 2026	根据输入长度自适应地分配多粒度位置分辨率	说明固定映射不足，但其目标仍主要是位置重映射
Periodic RoPE, 2026	局部 SWA 层使用 RoPE，全局层使用 NoPE	与“近程保序、远程去位置”最接近；采用固定的层间分工，没有在同一 head 内按检索置信度连续融合

工作	核心方法	对本项目的启发与不足
TriAttention, 2026	利用跨位置稳定的 pre-RoPE Q/K 中心和三角级数估计 KV 重要性	证明 pre-RoPE 空间适合稳定选 Key；主要目标是推理期 KV 压缩，而非把语义分数直接注入 attention
RoPE-ID / Frayed RoPE, ICLR 2026	只在部分通道施加高频 RoPE，以保持训练内 Q/K 簇分离	支持通道选择；其核心解释是 sink 功能和簇分离，而本文关注证据 QK、softmax 和 residual 因果链
ScoPE, ACL 2026	用不同 head 的指数级回看范围代替显式位置算术	表明顺序可由层级稀疏拓扑表达；但不是预训练 RoPE 模型的直接 retrofit
RoPE Distinguishes Neither Positions Nor Tokens, 2026	理论证明长上下文下会出现 position/token inversion 与 aliasing	说明仅调大 base 不能同时保住位置区分和 token 语义排序，需要结构性解耦

3.2 与我们的区别

已有方法大致分成三类：

1. 调整频率或位置映射；
2. 对远程位置截断、分组或降低分辨率；
3. 交替使用 RoPE 与 NoPE。

本项目更关注一个具体缺口：

对预训练好的模型，在每层每个 head 内，根据远程语义检索置信度，连续决定保留多少 post-RoPE 分数，并控制进入 softmax 的远程候选数量。

这个组合与 HoPE、RNoPE、Periodic RoPE、TriAttention 都有邻近关系，因此不能仅以“远程 NoPE”或“pre-RoPE 检索”作为创新点。可区分的部分必须是：

1. 同一 head 内的连续、置信度驱动门控，而非固定拆层；
2. pre-RoPE 负责远程候选，post-RoPE 保留训练内行为；
3. 逐 head 分布校准，使两个分数通道能进入同一个 softmax；
4. 候选预算与证据块位置修复联合设计；
5. 用 attention mass $\rightarrow$ residual $\rightarrow$ output margin 的因果指标训练或校准门控。

因此目标不是追求一个对所有 head、所有 token 都相同的新 base，而是把：

- 语义召回；
- 局部顺序；
- 分数尺度；
- softmax 候选预算；

放入同一个 attention 机制中。

4. Final: SAGE-RoPE 长程检索方案

方案由五个模块组成，但当前验证程度不同：

模块	作用	本轮状态
局部 RoPE + 远程 pre-RoPE 召回	拆开近程顺序与远程语义	已在 GPU7 验证
逐 head 分数校准	统一 pre/post 分数尺度	已在 GPU7 验证
pre/post 双路候选	避免任一路单独漏证据	已在 GPU7 验证
连续门控	保留预训练 RoPE，同时有限引入语义分数	固定 25% 已验证，学习式门控待验证
证据块位置修复	保持块内顺序并缩短虚拟距离	方案已推导，本轮末端到端验证

4.1 两个分数通道

标准 post-RoPE 分数：

$$s_{l,h}^R(t,j) = \frac{(R_t q_{l,h})^\top (R_j k_{l,h,j})}{\sqrt{d}}.$$

位置无关的语义分数：

$$s_{l,h}^C(t,j) = \frac{q_{l,h}^\top k_{l,h,j}}{\sqrt{d}}.$$

其中 C 表示 content。

4.2 每个 head 单独校准

pre-RoPE 与 post-RoPE 分数的均值、方差可能不同，不能直接放入同一个 softmax。对每层每个 head 做：

$$\hat{s}_{l,h}^C = \mu_{l,h}^R + \frac{\sigma_{l,h}^R}{\sigma_{l,h}^C + \epsilon} (s_{l,h}^C - \mu_{l,h}^C).$$

校准只使用当前 head 的分数统计，不需要证据标签。

4.3 近程保序、远程语义召回

定义局部窗口 W 。候选集合为：

$$\mathcal{C}_{l,h} = \mathcal{L}_W \cup \mathcal{S} \cup \text{TopK}(\hat{s}_{l,h}^C, \Delta > W),$$

其中：

- $\mathcal{L}_W$ ：最近 W 个 token；
- $\mathcal{S}$ ：少量 sink/结构 token；
- TopK：远程语义候选；
- 总候选数控制为原上下文的约 2%。

4.4 连续门控，不做硬切换

对候选 token：

$$s_{l,h}^{\text{SAGE}}(t,j) = \begin{cases} s_{l,h}^R(t,j), & \Delta \leq W, \\ (1 - g_{l,h})s_{l,h}^R(t,j) + g_{l,h}\hat{s}_{l,h}^C(t,j), & \Delta > W, j \in \mathcal{C}_{l,h}, \\ -\infty, & \text{otherwise.} \end{cases}$$

第一版可以固定：

$$g_{l,h} = 0.5.$$

更完整的版本让 $g_{l,h}$ 由以下信号学习或离线校准：

- head 是否承担远程证据检索；
- 语义 Top-1/Top-2 margin；
- 分数熵；
- 距离；
- 当前层；
- pre/post 排名一致性。

4.5 证据块的位置修复

单 token 检索容易破坏句内结构。对召回的证据块 B ，设块锚点为 a_B ，将整块平移到 Query 前的训练内距离 W ：

$$p'_j = t - W - (a_B - j), \quad j \in B.$$

这样：

- 块内相对顺序 $j_2 - j_1$ 不变；
- 整块与 Query 的距离被压回模型熟悉范围；
- recent token 的原位置完全不动；
- 避免此前“把所有选中 token 逐个挤到 Query 前”造成的格式破坏。

4.6 最终建议：保守、可回退的逐 head 门控

固定 $g = 0.5$ 只适合验证两个分数通道能否结合，不应作为最终实现。令：

- $m_{l,h}^C$ ：语义 Top-1 与 Top-2 的标准化 margin；
- $H_{l,h}^C$ ：语义候选分布的标准化熵；
- $D_{l,h}^{CR}$ ：pre/post 排名分歧；
- $\pi_{l,h} \in [0, 1]$ ：该 head 的远程证据读取先验；
- $\bar{\Delta}_{l,h}$ ：入选远程候选的平均距离。

采用有上限的门控：

$$g_{l,h} = g_{\max} \pi_{l,h} \sigma \left(\alpha m_{l,h}^C - \beta H_{l,h}^C + \gamma D_{l,h}^{CR} + \eta \log \left(1 + \frac{\bar{\Delta}_{l,h}}{W} \right) - \tau_{l,h} \right).$$

结合 GPU7 验证，第一版取 $g_{\max} = 0.25$ 更保守；当语义检索不确定、上下文较短或该 head 不承担证据读取时，门控自动回到接近标准 RoPE。同时让局部窗口受预算约束：

$$W(N) = \min(W_{\max}, \lfloor \lambda \rho N \rfloor), \quad 0 < \lambda < 1,$$

避免短上下文中固定 local window 吃掉几乎全部 2% 候选预算。训练或离线校准时使用：

$$\mathcal{L} = \mathcal{L}_{\text{answer}} + \lambda_{\text{short}} D_{\text{KL}}(P_{\text{SAGE}}^{\text{short}} \| P_{\text{RoPE}}^{\text{short}}) + \lambda_g \sum_{l,h} g_{l,h}.$$

第二项约束短程行为不偏离预训练模型，第三项惩罚不必要的语义干预。因此该方案具备明确回退路径：门控失败时退回 post-RoPE，而不是像纯 pre-RoPE 一样彻底改变预训练 attention 几何。

5. 实验支撑：GPU7 对照实验

5.1 资源约束

- 只暴露物理 GPU7；
- Qwen3-8B；
- NF4 量化模型权重，用于让单张 24GB 3090 容纳 64K KV cache；
- 8K、16K、32K、64K；
- 4 个随机种子；
- 每层每个 head 总预算约 2%。

5.2 对照方法

1. `full_rope`：标准 Full Attention；
2. `rope_top2`：原 post-RoPE Top-2%；
3. `semantic_top2_postscore`：pre-RoPE 只负责选择，仍用 post-RoPE 打分；
4. `local_global_raw`：近程 RoPE + 远程原始 pre-RoPE；
5. `local_global_calibrated`：加入逐 head 分数校准；
6. `local_global_blend50`：校准语义分数与 post-RoPE 各占 50%；
7. `local_global_blend25`：保留 75% post-RoPE，只加入 25% 校准语义分数；
8. `dual_max_blend25`：用 pre/post 两路分数的逐 token 最大值选候选，再以 75%/25% 融合打分。

5.3 指标

- Gold evidence token recall；
- 两条证据链的 line hit / chain complete；
- 证据 attention mass；
- Gold PPL；
- 首答案 token 准确率；

- Query 阶段耗时。

5.4 4K 冒烟结果

方法	证据 token recall	证据 mass	Gold PPL	首 token 正确
Full RoPE	100.00%	5.872%	2.618	是
post-RoPE Top-2%	22.21%	5.875%	4.854	否
pre-RoPE 选、post-RoPE 打分	29.60%	5.989%	363,947	否
Local/Global raw	14.17%	3.783%	3.62×10^8	否
Local/Global calibrated	17.19%	5.279%	3.054	否
Local/Global blend 50%	20.08%	5.976%	2.701	是

早期结果已经排除两个过度简化的假设：


1. “远程完全改成 pre-RoPE 就会更好”不成立；
2. “证据召回率提高即可保证答案更好”不成立。

逐 head 校准和保留部分 post-RoPE 是必要的。

5.5 正式 8K–64K 结果

下表为 seeds 0–3 的几何平均 PPL；括号内是首答案 token 准确率：

长度	Full RoPE	post-RoPE Top-2%	SAGE, $g = 0.5$	SAGE 证据 recall	SAGE 证据 mass
8K	2.247 (75%)	1.905 (75%)	2.800 (50%)	14.41%	5.584%
16K	7.296 (50%)	3.232 (75%)	6.429 (25%)	41.63%	5.469%
32K	10.137 (25%)	7.129 (50%)	5.126 (50%)	46.81%	4.983%
64K	11.867 (0%)	9.759 (25%)	9.679 (25%)	39.26%	1.983%



逐样例配对后，SAGE 相比 Full RoPE 降低 Gold NLL 的样例比例分别为 50%、75%、100%、75%。它在 32K-64K 最有帮助，在 8K 没有优势；这符合“只为远程检索改变位置机制”的目标，而不是宣称它应替代短程 RoPE。

两个重要限制也已经暴露：

1. 8K 时总预算只有约 164 个 token，而固定的 128-token local window 和 16 个 sink 几乎用完预算，留给远程语义召回的槽位过少；
2. 64K 的全 head 平均证据 mass 仍明显下降，说明固定 $g = 0.5$ 会在一些不适合语义分数的 head 中过度干预，需要逐 head 门控，而不是继续统一增大 pre-RoPE 权重。

5.6 独立 seeds 4-7 验证


根据前四个 seed 暴露的问题，只在独立 seeds 4-7 上增加较保守的 25% 融合和 dual-max 候选，不回头调这四个样例：

长度	Full RoPE	post-RoPE Top-2%	SAGE 25%	SAGE dual-max 25%
32K	21.048 (0%)	15.382 (25%)	3.806 (25%)	4.301 (25%)
64K	5.892 (50%)	4.321 (75%)	4.049 (75%)	3.625 (75%)

括号仍是首答案 token 准确率。进一步看机制指标：

长度	方法	证据 token recall	两链均命中	证据 mass
32K	post-RoPE Top-2%	39.61%	60.74%	4.945%
32K	SAGE 25%	47.65%	80.27%	5.490%

长度	方法	证据 token recall	两链均命中	证据 mass
64K	post-RoPE Top-2%	35.59%	55.03%	3.983%
64K	SAGE 25%	43.49%	77.50%	3.886%



因此目前最稳的无训练原型不是“远程完全 NoPE”，而是：

pre/post 双路保召回 + 75% post-RoPE + 25% 校准 pre-RoPE

32K 下 25% 单路语义选择更好，64K 下 dual-max 更好，说明最终实现应让候选集合保留 pre/post 两路，而门控决定打分时使用多少语义通道。不过每个长度只有 4 个独立 seed，这仍是机制性 proof-of-concept，不是大规模 benchmark 结论。

本轮 GPU7 实验已经验证了候选选择、逐 head 校准和分数融合；第 4.5 节的块位置修复以及第 4.6 节的学习式门控尚未在本轮端到端实验中启用，应作为下一阶段实现，而不能算作已经验证的收益来源。

6. 最终结论

从理论、已有 140K 边界数据和近期工作看，最合理的方向不是继续寻找一个统一的 RoPE base，而是：

局部顺序 RoPE + 远程语义检索 + 逐 head 连续门控 + 块内位置修复 + 稀疏 softmax

它同时处理两个不同问题：

- RoPE 相位会翻转远程 token 的语义排序；
- 即使找回正确证据，过多远程候选仍会通过 softmax 分母稀释证据。

所以更好的长程方案必须同时改变“远程如何编码”和“哪些远程 token 有资格进入 softmax”，只改其中一个通常不够。

7. 复现实验与产物

三组任务均由脚本显式设置 `CUDA_VISIBLE_DEVICES=7`：

- 第一层精确相位分解：
`scripts/run_first_layer_rope_phase_gpu7_20260730.sh`;
- seeds 0-3 主实验：
`scripts/run_local_global_rope_probe_gpu7_20260730.sh`;
- seeds 4-7 独立验证：
`scripts/run_local_global_rope_validation_gpu7_20260730.sh`。

本地同步后的完整产物分别位于：

- `artifacts/20260730_first_layer_rope_phase_gpu7/`;
- `artifacts/20260730_local_global_rope_probe_gpu7/`;
- `artifacts/20260730_local_global_rope_validation_gpu7/`。

行数审计结果为 8,192 个二维频率对记录、96 个主实验

`length × seed × variant` 记录和 64 个独立验证记录，均与配置预期一致。