

问题：为什么上下文越长，大海捞针的正确答案置信度越低？

上下文变长时，通常同时发生两件事：

机制	发生了什么	直接结果
Softmax 竞争	N 增大，更多 filler token 进入分母	真实证据的 attention mass 被稀释
RoPE 方向变化	filler 插在证据与 Query 之间，使 Δ 增大	真实证据的 QK logit 在实验范围内总体下降

两项叠加，使证据写入 residual stream 的有效信号减弱，最终正确答案概率下降、PPL 上升。

序列变长

└ 候选 token 变多 → Softmax 分母变大 → 证据权重下降

└ 证据离 Query 更远 → RoPE 相位改变 → 证据 QK 分数下降

1. Softmax：证据分数不变，也会被更多 token 稀释

真实证据的 attention 权重为：

$$a_e = \frac{e^{s_e}}{e^{s_e} + \sum_{j \neq e} e^{s_j}}.$$

若每个 filler token 的平均指数分数为 $C = E[e^{s_d}]$ ，则：

$$a_e \approx \frac{e^{s_e}}{e^{s_e} + (N - 1)C}.$$

因此，即使 s_e 完全不变， N 增大也会让 a_e 下降。同时，候选越多，出现一个高分伪证据的概率也越高，真实证据的排名会进一步恶化。

这是一种数量竞争：不要求 Query 或真实证据 Key 的方向发生任何变化。

2. RoPE：距离变化会改变 Q 与 K 的相对方向

设 RoPE 前的内容向量为 q, k ，Query 和证据位置分别为 m, n ：

$$q_m = R(m)q, \quad k_n = R(n)k.$$


经过 RoPE 后的点积为：

$$s_e(\Delta) = \frac{q_m^\top k_n}{\sqrt{d}} = \frac{q^\top R(n - m)k}{\sqrt{d}}, \quad \Delta = n - m.$$

所以 RoPE 的位置影响只取决于相对距离 Δ 。在第 i 个二维频率对中，其贡献可以写成：

$$s_i(\Delta) = A_i \cos(\Delta \omega_i) + B_i \sin(\Delta \omega_i).$$

Head18 Layer11的q位置对于前面的k位置的Rope贡献波形图：



单个频率对会周期性增强或削弱匹配，并不是距离越远就必然单调变差。但是一个 head 同时叠加多个不同频率，而且 Q/K 的权重由模型训练得到；当 Δ 离开模型熟悉的距离范围时，各频率更容易由相长叠加变为相消叠加。在我们的 Qwen3-8B 长距离实验范围内，最终表现为真实证据的 post-RoPE logit 和 cosine 总体下降。

3. Qwen3-8B 实验支撑

相对距离增长：RoPE 是 QK 方向损失的主要来源

在证据位于文本中部、Query 位于末尾的 8K→128K 反事实分解中：

raw-logit 变化来源	贡献
Query 内容变化	+0.349
Key 内容变化	+0.371
相对位置 / RoPE	-4.630

pre-RoPE 的内容匹配没有退化，真正的主要负项是相对距离带来的 RoPE 旋转。

相对距离固定：RoPE 退化消失，但 Softmax 稀释仍存在

把 evidence-Query 距离固定为 328，仅把前置 filler 从短上下文扩展到 128K：

指标	短上下文	长上下文	变化
evidence raw logit	5.024	7.249	+2.226
head logsumexp	14.486	17.048	+2.562
evidence attention mass	0.723%	0.437%	降至 60.5%
Gold PPL 中位数	6.932	40.075	变坏 5.78×

这证明：**固定距离可以保住 QK 方向，却不能阻止更多候选 token 扩大 Softmax 分母。**

作为补充，64K 的 16 样本实验中，post-RoPE Top-2% 将大部分竞争 token 删除后，保留的证据 attention mass 为 3.913%，接近 Full Attention 的 4.113%；正确答案 PPL 从 Full 的 1.317 改善到 1.202。这支持“无效竞争 token 会降低答案置信度”的解释。

结论

长上下文不是简单地让模型“忘记”证据，而是同时改变了证据的相对匹配分数和竞争环境。

- 1. RoPE 决定能不能瞄准远处证据：**相对距离增长改变 QK 相位，使真实证据 logit 在当前任务和距离范围内总体下降。

2. **Softmax 决定证据能分到多少权重**：候选数量增长，即使证据 logit 不变，也会扩大分母并增加伪证据极值竞争。

相对距离增长主要解释 QK 方向退化；候选数量增长独立解释 Softmax 稀释；二者叠加导致正确答案概率降低。

附录：RoPE 旋转矩阵与二维频率贡献的推导

A.1 二维旋转矩阵是什么

设 attention head 的维度为 d ，RoPE 将这些维度组成 $d/2$ 个二维频率对。第 i 个频率对在位置 p 的旋转矩阵为：

$$R_i(p) = \begin{bmatrix} \cos(p\omega_i) & -\sin(p\omega_i) \\ \sin(p\omega_i) & \cos(p\omega_i) \end{bmatrix}.$$

其中 ω_i 是第 i 个二维对的角频率。标准 RoPE 通常使用：

$$\omega_i = \theta_{base}^{-2i/d}, \quad i = 0, 1, \dots, d/2 - 1.$$

Qwen3 在长上下文中可能通过 YaRN 等缩放策略调整实际使用的频率，但后面的推导不变：只需要把 ω_i 换成模型运行时的有效频率。

将所有二维旋转组合起来，可把完整旋转写成分块对角矩阵：

$$R(p) = \text{diag}(R_0(p), R_1(p), \dots, R_{d/2-1}(p)).$$

这里为了推导方便，把每个二维对写在相邻坐标中。Qwen3/Hugging Face 的实际张量布局采用 split-half 配对，即第 i 维与第 $i+d/2$ 维组成一对；两种写法只差一次固定的坐标重排，数学含义完全相同。

旋转矩阵有三个重要性质：

$$R(p)^\top R(p) = I, \quad R(p)^\top = R(-p), \quad R(a)R(b) = R(a+b).$$

因此 RoPE 不改变 Q/K 的长度，只改变它们的方向。

A.2 为什么 QK 点积只依赖相对位置

设 Query 位于 m ，Key 位于 n ，RoPE 前的内容向量为 q, k ：

$$q_m = R(m)q, \quad k_n = R(n)k.$$

则旋转后的点积为：

$$\begin{aligned} q_m^\top k_n &= (R(m)q)^\top R(n)k \\ &= q^\top R(m)^\top R(n)k \\ &= q^\top R(n-m)k. \end{aligned}$$

令相对位置 $\Delta=n-m$ ，就得到：

$$q_m^\top k_n = q^\top R(\Delta)k.$$

这说明共同移动 Query 和 Key 不会改变 RoPE 位置项；真正起作用的是二者的相对距离。

A.3 推导单个二维频率对的贡献

取第 i 个二维对，并记：

$$q_i = \begin{bmatrix} q_{i,x} \\ q_{i,y} \end{bmatrix}, \quad k_i = \begin{bmatrix} k_{i,x} \\ k_{i,y} \end{bmatrix}.$$

在相对位置 Δ 下，Key 被旋转为：

$$R_i(\Delta)k_i = \begin{bmatrix} k_{i,x} \cos(\Delta\omega_i) - k_{i,y} \sin(\Delta\omega_i) \\ k_{i,x} \sin(\Delta\omega_i) + k_{i,y} \cos(\Delta\omega_i) \end{bmatrix}.$$

与 Query 做点积并展开：

$$\begin{aligned} q_i^\top R_i(\Delta)k_i &= (q_{i,x}k_{i,x} + q_{i,y}k_{i,y}) \cos(\Delta\omega_i) \\ &\quad + (q_{i,y}k_{i,x} - q_{i,x}k_{i,y}) \sin(\Delta\omega_i). \end{aligned}$$

把 attention 的缩放因子也包含进系数，定义：

$$A_i = \frac{q_{i,x}k_{i,x} + q_{i,y}k_{i,y}}{\sqrt{d}}, \quad B_i = \frac{q_{i,y}k_{i,x} - q_{i,x}k_{i,y}}{\sqrt{d}}.$$

于是第 i 个二维频率对对 attention logit 的贡献就是：

$$s_i(\Delta) = A_i \cos(\Delta\omega_i) + B_i \sin(\Delta\omega_i).$$

整个 head 的 QK logit 是所有二维频率贡献之和：

$$s(\Delta) = \sum_{i=0}^{d/2-1} s_i(\Delta).$$

其中：

- A_i 、 B_i 由当前 token 的 Q/K 内容决定；
- ω_i 由 RoPE 频率配置决定；
- Δ 由证据与 Query 的相对位置决定。

还可以令：

$$C_i = \sqrt{A_i^2 + B_i^2}, \quad \phi_i = \text{atan2}(B_i, A_i),$$

从而得到等价形式：

$$s_i(\Delta) = C_i \cos(\Delta\omega_i - \phi_i).$$

这说明单个二维对是一条周期曲线，周期为 $2\pi/\omega_i$ ； C_i 决定振幅， ϕ_i 是由 Q/K 内容决定的初始相位。一个 head 的整体曲线则是多个不同频率周期项的加权叠加，所以不会表现为一条简单、单调的距离衰减曲线。