

基于 PCA64 INT4 的层次化 Per-Head KV 检索

更新时间：2026-07-17

1. 问题

前期实验发现：长上下文中，每个 query head 只保留真实 attention score 最高的2%历史 token，仍能保持接近 Full Attention 的质量。

在体育和医学各3个32K窗口上的结果为：

主题	Full PPL	Per-head exact top-2% PPL	相对质量保持
体育	8.0679	8.3369	96.78%
医学	8.7336	8.8821	98.33%
合并	--	--	97.55%

这说明模型并不需要对全部历史 token 做 attention，关键在于找到每个 head 真正需要的少量 token。

但上述 exact top-2% 是诊断上界：为了得到真实排名，仍然计算了完整 QK：

score(head h, token i) = dot(query_h, key_h,i), i = 1 ... N

因此，问题被定义为：

如何不计算完整 QK，就低成本找到每个 query head 的 top-2% 高 attention token？

注意：现有结果支持“接近 Full”，不支持“稳定超越 Full”。个别任务可能高于 Full，但体育和医学的合并 PPL 比 Full 高2.51%。

2. 新发现

我们对每层、每个 KV head 的 post-RoPE K 建立 PCA64 低维空间，并将64维投影结果量化为 INT4。当前 query 投影到同一空间后，用低维内积近似 QK score。

索引只占完整 FP16 K+V 的 **6.64%**。在体育和医学的真实32K Q/K trace上，共测试320个 layer-head-query case：

指标	PCA64 INT4
Exact top-2% token recall	68.11%
Token recall p10	57.61%
Oracle top-2% attention mass recall	98.27%
Mass recall p10	95.81%
Mass recall minimum	87.34%

核心发现是：

PCA64 INT4 只召回68.11%的 exact top-2% token，却召回98.27%的 oracle attention mass。

原因是 top-2% 内部并不等权。低维索引遗漏的主要是低权重尾部 token，而高 attention mass token 更容易保持高分。

另一个发现是，不同 query heads 需要不同历史证据。128K实验中，让同一GQA组共享一套候选时，质量保持率只有78.07%；改为每个 query head 独立检索后，质量恢复到96.34%。

3. 设计的方法

基于上述发现，我们设计了层次化 Per-Head KV Retrieval：

1. **GPU全局索引**：保存每个历史 K 的 PCA64 INT4 表征，用于扫描和定位候选；
2. **CPU完整K/V**：完整 FP16 K/V 保存在 pinned memory，不做不可逆删除；
3. **Per-query-head检索**：每个 query head 独立选择1%--2.5%的历史 token；
4. **GPU精确热缓存**：保存3.2%--4.1%的精确 FP16 K/V，cache miss才从CPU搬运；
5. **精确稀疏attention**：最终使用被选中的原始 FP16 K/V，而不是PCA近似值；
6. **Residency-windowed GQA**：每次只处理一个或两个 query heads，复用同一批GPU cache slots，避免逐头候选并集膨胀。

整体流程为：

```
Query
-> PCA64投影
-> INT4全局索引扫描
-> 每个query head独立选择候选
-> 查询GPU精确K/V热缓存
-> 从CPU填充cache miss
-> 在精确FP16 K/V上计算稀疏attention
```

短上下文中检索开销不能摊销，因此当前使用纯长度gate：

少于16K: Full Attention
16K及以上: 层次化Per-Head KV Retrieval

该方法不读取答案，不使用任务标签、oracle或测试集router。

4. 最终效果

场景	质量保持率	GPU KV ratio	Decode speedup	Protocol/E2E speedup
LongBench 16任务, 3750样本	96.66%	10.62%	旧协议不报告	旧协议不报告
LongBench新协议, 160样本	98.59%	10.66%	0.283x raw sparse	长度gate后等于Full
128K speed-first	96.34%	9.99%	2.706x	1.126x
128K quality-first	99.84%	11.00%	2.383x	1.069x

其中，128K的2.706x是整模型decode加速，已经包含PCA64 INT4扫描、top-k、cache查询、PCIe搬运、精确稀疏attention、MLP及其他模型计算。

可以用于汇报的总结是：

逐head exact top-2%实验首先证明了长上下文attention具有极强稀疏性。随后，我们发现PCA64 INT4索引能以68.11%的token召回恢复98.27%的oracle attention mass。基于这一特性设计的层次化KV检索系统，在完整LongBench上用10.62% GPU KV保持96.66%质量，并在一个128K开发窗口上用9.99% GPU KV保持96.34%质量、取得2.706x整模型decode加速。

当前边界：128K速度结果仍来自单主题、单窗口；完整LongBench证明了质量，但其旧协议不能用于速度结论。