

QKSieve

1. 要解决的问题

对一个 query head，标准自回归 attention 在长度为 N 的历史 KV 上计算

$$\ell_i = \frac{q^\top k_i}{\sqrt{d}}, \quad o = \frac{\sum_{i=1}^N e^{\ell_i} v_i}{\sum_{i=1}^N e^{\ell_i}}.$$

每生成一个 token，都要读取全部 K/V，计算量和显存带宽均随 N 线性增长。

不扫描完整 FP16 K/V，如何为每个 query head 找到少量高权重 token，近似 Full Attention 计算？

2. 先验经验

1、对于模型的每层每个head只需要retrival attention最高的top2%的token就能够保持推理质量。

3. 当前效果

模型为 Llama-3.1-8B-Instruct，质量在 held-out mixed_b 的 32 个teacher-forced token 上测量；质量保持率定义为 $\exp(\text{NLL}_{\text{full}} - \text{NLL}_{\text{sparse}})$ 。超过 100% 只代表该小 probe 的 NLL 略低，不能解释为普遍超过 Full。

历史长度	实际 token/head	Active 比例	质量保持	Top-1	Full decode	QKSieve decode	加速
32K	1,276.17	3.895%	100.812%	100%	87.46 ms	45.52 ms	1.921x
64K	1,276.58	1.948%	101.358%	100%	151.22 ms	62.77 ms	2.409x
128K	1,278.86	0.976%	100.526%	100%	277.64 ms	89.89 ms	3.089x

补充资源结果：

- 低比特 Key 索引约占完整 FP16 K+V 的 **5.8%**；ValueSketch 约占**1.61%**；总辅助索引约为 **7.4%**。
- 一次性索引成本在 32K/64K/128K 分别约为 3.17/3.35/3.58 s；按实测 decode 斜率，分别生成约 76/38/19 个 token 后回本。

完整 LongBench 的已有 QKSieve full-proxy 参考路径在 16 个英文任务、3,750样本上取得 0.458852，Full 为 0.459398，即 **99.881%**。

4. 方法

当前冻结原型为

qksieve_qmse_oas_requestlocal_valuesketch16_sorted_c64_k1280，流程如下。

1. 请求内 **QK-balanced** 坐标。Prefill 后，按层和 KV head 估计 Query/Key 二阶矩，构造保持完整 dot product 的双正交坐标。

2. **混合位宽 band 索引。** 将 128 维分成八个 16-D band；每个 band 从 0/1/2/4/8 bit 中选择，使用 qMSE 和 OAS 收缩，在每 token/head 240-bit 总预算下自动分配位宽。
3. **确定性 sampled-quantile 检索。** 目标候选数为 $\min(\max(6\%N, 256), 1280)$ ；采样数随目标尾部概率缩放，使阈值样本中预计保留 64 个上尾锚点。随后只做一次低比特全历史扫描，以阈值直接产生逐 query-head 候选，不执行通用 top-k 或 exact rerank。
4. **候选精确计算。** 对候选读取 GPU 常驻的原始 FP16 K/V，计算精确 QK、softmax 分母和 Value 分子。
5. **ValueSketch 尾部补偿。** 对未选 token 使用 W_O -aware rank-16、block-256、INT4 ValueSketch，累计尾部 softmax 分母和 16 维低秩分子，并与候选的精确结果在同一指数标尺下合并。
6. **融合与确定性执行。** 代理扫描、候选 bitmask、尾部统计一次完成；候选使用固定前缀扫描压缩，尾部使用固定树归约。新 token 只增量追加 Key 编码和 ValueSketch 编码。

5. 核心数学推导

5.1 QK-balanced 坐标

对一个 KV head，分别用当前请求的 Query 与 Key 样本估计非中心二阶矩

$$\hat{C}_q = \frac{1}{m_q} \sum_j q_j q_j^\top, \quad \hat{C}_k = \frac{1}{m_k} \sum_i k_i k_i^\top.$$

对 Query 矩做各向同性收缩，对 Query/Key 矩做特征值 floor，得到正定矩阵 $\tilde{C}_q, C_k$ 。当前实现中，坐标构造使用 0.5 Query 收缩；后面的 band qMSE 使用数据自适应 OAS 收缩。

令

$$\tilde{C}_q^{1/2} C_k^{1/2} = U \Sigma V^\top,$$

并定义

$$A = \tilde{C}_q^{-1/2} U \Sigma^{1/2}, \quad D = C_k^{-1/2} V \Sigma^{1/2}.$$

因为

$$A D^\top = I,$$

所以对任意 q, k ,

$$q' = A^\top q, \quad k' = D^\top k, \quad q'^\top k' = q^\top k.$$

完整 128 维变换本身不产生 score 误差。同时，

$$A^\top \tilde{C}_q A = D^\top C_k D = \Sigma,$$

在构造时采用的二阶模型

$\mathbb{E}[q q^\top] = \tilde{C}_q$ 、 $\mathbb{E}[k k^\top] = C_k$ 下，其逐步推导为

$$\begin{aligned}
\mathbb{E}[q'q'^\top] &= A^\top \mathbb{E}[qq^\top] A \\
&= A^\top \tilde{C}_q A \\
&= \Sigma^{1/2} U^\top \tilde{C}_q^{-1/2} \tilde{C}_q \tilde{C}_q^{-1/2} U \Sigma^{1/2} \\
&= \Sigma,
\end{aligned}$$

以及

$$\mathbb{E}[k'k'^\top] = D^\top C_k D = \Sigma.$$

由于 $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_d)$, 对任意坐标 r, s ,

$$\mathbb{E}[q'_r q'_s] = \sigma_r \mathbf{1}[r = s], \quad \mathbb{E}[k'_r k'_s] = \sigma_r \mathbf{1}[r = s].$$

特别地,

$$\boxed{\mathbb{E}[(q'_r)^2] = \mathbb{E}[(k'_r)^2] = \sigma_r}.$$

这里是**非中心二阶矩**。只有当坐标均值为零时, 它才等于通常意义下的方差。

若使用原始经验 Query 矩而不是构造变换时的收缩矩, 则

$$\frac{1}{m_q} \sum_j q'_j q'_j{}^\top = \Sigma + \Delta_q, \quad \Delta_q = A^\top (\hat{C}_q - \tilde{C}_q) A.$$

因此原始样本上准确的坐标结论是

$$\frac{1}{m_q} \sum_j (q'_{j,r})^2 = \sigma_r + (\Delta_q)_{rr},$$

而不是无条件严格等于 σ_r ; Key 侧同理。 Δ_q, Δ_k 应在实验中直接测量。

进一步, 在 Query 与 Key 按各自二阶分布独立抽样的模型下,

$$q^\top k = q'^\top k' = \sum_{r=1}^d q'_r k'_r.$$

第 r 个坐标的 score 二阶能量为

$$\mathbb{E}[(q'_r k'_r)^2] = \mathbb{E}[(q'_r)^2] \mathbb{E}[(k'_r)^2] = \sigma_r^2.$$

不同坐标的交叉项为零, 因此

$$\mathbb{E}[(q'^\top k')^2] = \sum_{r=1}^d \sigma_r^2.$$

所以第 g 个 16-D band 的理论 score 能量为

$$E_g = \sum_{r=16(g-1)+1}^{16g} \sigma_r^2.$$

前部 band 因奇异值更大而承载更多联合 QK score 能量。这说明坐标按 Query 与 Key 的联合 score 能量排序, 而不是只按 Key 重构能量排序。真实 attention 中的 Query 与 Key 可能相关, 此时 σ_r^2 分解是二阶独立模型下的结论, 需要用真实轨迹的逐 band score 能量验证; 当前 91.22%/96.57% 正是这一验证。

在 Query/Key 独立二阶模型下, 最优 rank- r 双线性近似的误差为

$$\min_{\text{rank}(B) \leq r} \mathbb{E} [(q^\top k - q^\top Bk)^2] = \sum_{j>r} \sigma_j^2.$$

这给出了按联合奇异值顺序切分 band 的依据。

5.2 Band 量化与 qMSE 位宽分配

将 q', k' 划分为八个 16 维 band:

$$q' = (q'_1, \dots, q'_8), \quad k' = (k'_1, \dots, k'_8).$$

第 g 个 band 使用 $b_g \in \{0, 1, 2, 4, 8\}$ bit. $b_g = 0$ 时该 band 置零;

$b_g \geq 2$ 时使用逐 token 对称整数码:

$$a_{i,g} = \frac{\|k'_{i,g}\|_\infty}{2^{b_g-1}-1}, \quad \hat{k}'_{i,g} = a_{i,g} \text{ clip} \left(\text{round} \frac{k'_{i,g}}{a_{i,g}} \right).$$

1-bit band 使用 sign code 和平均绝对值 scale. 每个 active band 还保存一个 FP16 scale, 相当于每坐标多 1 bit, 因此物理成本为

$$R(b) = 16 \sum_{g=1}^8 (b_g + \mathbf{1}[b_g > 0]) \leq 240 \text{ bit}.$$

令 $e_{i,g}(b) = k'_{i,g} - \hat{k}'_{i,g}(b)$. 第 g 个 band 的分数失真为

$$D_g(b) = \frac{1}{m_q m_k} \sum_{j,i} \left(q'_{j,g}^\top e_{i,g}(b) \right)^2 = \text{tr}(C_{q,g} C_{e,g}(b)).$$

由于每个 head 只有少量 prefill Query, 使用 OAS 将经验 Query 二阶矩向各向同性矩阵收缩:

$$\begin{aligned} \bar{C}_q &= (1 - \alpha) \hat{C}_q + \alpha \frac{\text{tr}(\hat{C}_q)}{d} I, \\ \alpha &= \text{clip}_{[0,1]} \frac{(1 - 2/d) \text{tr}(\hat{C}_q^2) + \text{tr}(\hat{C}_q)^2}{(m_q + 1 - 2/d) [\text{tr}(\hat{C}_q^2) - \text{tr}(\hat{C}_q)^2/d]}. \end{aligned}$$

最终 allocation 为

$$b^* = \arg \min_b \sum_{g=1}^8 D_g(b_g) \quad \text{s.t.} \quad R(b) \leq 240.$$

八个 band、五种位宽和 15 个归一化成本单位可用动态规划精确求解:

$$F(g, r) = \min_{b: r_g(b) \leq r} [F(g-1, r - r_g(b)) + D_g(b)].$$

因此, 在冻结坐标、量化器和校准 qMSE 下, 该分配不差于任何同预算固定 `[4, 1]`、`[4, 2, 2, 1]` 等配置. 完整 score MSE 还包含跨 band 项

$$\Gamma = \sum_{g \neq h} \text{tr}(C_{q,gh} C_{e,hg}),$$

其绝对值满足

$$|\Gamma| \leq \sum_{g \neq h} \|C_{q,gh}\|_F \|C_{e,hg}\|_F.$$

所以 band 可分是可测近似，不是无条件假设。在线 Query 还按 band 量化为 INT8；总代理误差可写成

$$q'^{\top} k' - \hat{q}'^{\top} \hat{k}' = q'^{\top} (k' - \hat{k}') + (q' - \hat{q}')^{\top} \hat{k}'.$$

qMSE allocation 直接优化第一项，第二项由 INT8 Query 精度和内核等价性实验单独控制。

5.3 长度连续的 sampled-quantile 候选

候选目标为

$$k(N) = \min(N, \max(256, \min(\lceil 0.06N \rceil, 1280))), \quad p = \frac{k(N)}{N}.$$

固定采样数会使长序列中的目标上尾样本越来越少。令期望上尾锚点数 $c = 64$ ，采用

$$m(N) = \text{clip}_{[256, 8192]} \left(256 \left\lceil \frac{c/p}{256} \right\rceil \right).$$

每个 query head 使用分层等距、确定性相位偏移的位置采样代理 logit $\hat{\ell}_i$ ，取样本的目标上尾 order statistic 为阈值 τ ，然后

$$S = \{i : \hat{\ell}_i \geq \tau\}, \quad T = \{1, \dots, N\} \setminus S.$$

该规则使阈值估计在不同长度下都约有 64 个上尾锚点。它不保证每个 head 恰好选中 k 个 token，但避免了完整分数物化和通用 top-k 排序。

5.4 W_O -aware rank-16 ValueSketch

候选使用原始 Value；ValueSketch 只近似 T 。对一个 KV head 关联的 GQA query heads，令对应输出投影块为 $W_{O,a}$ ，定义输出敏感度矩阵

$$G = \sum_{a \in \mathcal{G}(h)} W_{O,a}^{\top} W_{O,a}.$$

取 $G + \varepsilon I = LL^{\top}$ 。对 Value 样本均值 μ ，在变换空间

$$y_i = L^{\top} (v_i - \mu)$$

上做 PCA，取前 $r = 16$ 个特征向量 U_r 。定义

$$z_i = U_r^{\top} L^{\top} (v_i - \mu), \quad B = L^{-\top} U_r,$$

则

$$v_i \approx \hat{v}_i = \mu + Bz_i.$$

这等价于优先最小化经过 W_O 后的 Value 重构误差，而不是原始 Value 的普通欧氏误差。

将每 256 个 token 作为一块，对每个低秩维度独立做 INT4 仿射量化：

$$s_{b,r} = \frac{z_{b,r}^{\max} - z_{b,r}^{\min}}{15}, \quad c_{i,r} = \text{clip}_{[0,15]} \text{round} \frac{z_{i,r} - z_{b,r}^{\min}}{s_{b,r}},$$

$$\hat{z}_{i,r} = z_{b,r}^{\min} + s_{b,r} c_{i,r}.$$

16 个 INT4 系数占 8 Byte/token/KV-head; block min/scale 均摊约 0.25 Byte, 合计约为完整 FP16 K+V 的 **1.61%**。

5.5 尾部 softmax 补偿

代理扫描已经遍历所有 token, 因此在判断 $i \in S$ 的同时, 对 $i \in T$ 累计阈值中心化权重

$$\tilde{w}_i = e^{\hat{\ell}_i - \tau}.$$

只需保存 17 个充分统计量:

$$\tilde{D}_T = \sum_{i \in T} \tilde{w}_i, \quad \tilde{c}_T = \sum_{i \in T} \tilde{w}_i \hat{z}_i.$$

尾部 Value 分子为

$$\tilde{N}_T = \sum_{i \in T} \tilde{w}_i \hat{v}_i = \tilde{D}_T \mu + B \tilde{c}_T.$$

候选使用原始 FP16 K/V。令

$$m = \max_{i \in S} \ell_i, \\ D_S = \sum_{i \in S} e^{\ell_i - m}, \quad N_S = \sum_{i \in S} e^{\ell_i - m} v_i.$$

将尾部从阈值标尺转换到候选最大值标尺:

$$\rho = e^{\tau - m}.$$

当前版本不使用学习增益, 补偿系数固定为 1, 最终输出为

$$\hat{o} = \frac{N_S + \rho \tilde{N}_T}{D_S + \rho \tilde{D}_T}.$$

若代理 logit 精确, 即 $\hat{\ell}_i = \ell_i$, 且 ValueSketch 精确, 即 $\hat{v}_i = v_i$, 则

$$\rho \tilde{D}_T = \sum_{i \in T} e^{\ell_i - m}, \quad \rho \tilde{N}_T = \sum_{i \in T} e^{\ell_i - m} v_i,$$

从而 $\hat{o} = o$ 。因此补偿机制在理想条件下严格恢复 Full Attention; 实际误差只来自低比特 score 权重与 rank-16 INT4 Value 近似, 而不是来自稀疏集合内重新归一化。

进一步令同一标尺下的真实尾部统计量为

$$D_T = \sum_{i \in T} e^{\ell_i - m}, \quad N_T = \sum_{i \in T} e^{\ell_i - m} v_i,$$

并定义近似误差

$$\Delta_D = \rho \tilde{D}_T - D_T, \quad \Delta_N = \rho \tilde{N}_T - N_T.$$

则存在精确误差恒等式

$$\hat{o} - o = \frac{\Delta_N - o \Delta_D}{D_S + D_T + \Delta_D},$$

并有

$$\|\hat{o} - o\| \leq \frac{\|\Delta_N\| + \|o\| |\Delta_D|}{D_S + \rho \tilde{D}_T}.$$

该式把剩余风险拆成两个可独立测量的量：尾部 partition 误差 $|\Delta_D|$ 和尾部 Value 分子误差 $\|\Delta_N\|$ 。

6. 复现入口

- 方法配置与 ValueSketch: `src/run_head_top2_targeted_pp1_20260714.py`
- 低比特扫描与确定性压缩: `src/mixedblock_spectral_cuda_20260729.py`
- 候选/尾部 softmax 合并: `src/qksieve_valuesketch_cuda_20260801.py`
- 当前结果:
`docs/deterministic_sampled_valuesketch_20260804/visualization_results.md`
- 当前 variant: `qksieve_qmse_oas_requestlocal_valuesketch16_sorted_c64_k1280`